IST309 Örnekleme

Tabakalı Rastgele Örnekleme: Örneklem Büyüklüğünün Tabakalara Dağıtımı ve Örneklem Büyüklüğü

Prof. Dr. Nursel Koyuncu

Hacettepe Üniversitesi, İstatistik Bölümü

Bu Derste

1. Dağıtım Problemi ve Maliyet Fonksiyonu
2. En İyi (Optimum) Dağıtım
3. Neyman, Orantılı ve Eşit Dağıtım
4. Uygulamada Karşılaşılan Sorunlar
5. TRÖ'de Örneklem Büyüklüğü (Ortalama ve Toplam)
6. Oran Tahmini İçin Dağıtım ve Örneklem Büyüklüğü
7. Çözümlü Problemler
8. R ile Uygulama
9. Özet ve Alıştırmalar

İçerik

1. Dağıtım Problemi ve Maliyet Fonksiyonu
2. En İyi (Optimum) Dağıtım
3. Neyman, Orantılı ve Eşit Dağıtım
4. Uygulamada Karşılaşılan Sorunlar
5. TRÖ'de Örneklem Büyüklüğü (Ortalama ve Toplam)
6. Oran Tahmini İçin Dağıtım ve Örneklem Büyüklüğü
7. Çözümlü Problemler
8. R ile Uygulama
9. Özet ve Alıştırmalar

Dağıtım Problemi

TRÖ'de toplam örneklem büyüklüğü n belirlendikten sonra şu soru kalır:

"n birim, L tabakaya nasıl paylaştırılmalı? $n_1, n_2, \ldots, n_L = ?$"

Araştırmalarda **maliyet** ve **varyans** birlikte önemli rol oynar:

- Bazı araştırmalarda **maliyet önceden belirlenmiştir** $\Rightarrow$ varyans en küçük tutulmalıdır.
- Bazılarında **varyans (duyarlılık) bellidir** $\Rightarrow$ maliyet en küçük olmalıdır.
- Her iki durumda da örneklem büyüklüğünün tabakalara **en iyi** dağıtılması gerekir.

Bu derste

Dağıtım yöntemleri	eşit, orantılı, Neyman, optimum (en iyi)
Örneklem büyüklüğü	verilen maliyet için / verilen varyans için
Parametreler	ortalama, toplam, oran

Maliyet Fonksiyonları

Doğrusal maliyet fonksiyonu (en basit ve en yaygın)

$$M = M_0 + \sum_{h=1}^{L} m_h n_h$$

- M_0: genel (sabit) giderler: planlama, anket tasarımı, eğitim, analiz, raporlama.
- m_h: h. tabakada **birim başına** gider (görüşme, ulaşım, veri girişi).
- Tabakalar arası m_h farkı gerçekçidir: kırsal bölgede bir haneye ulaşmak kentsel bölgeden pahalıdır.

Gezi maliyeti içeren fonksiyon (Cochran, 1963)

Tabakalarda birimlere ulaşma (gezi) maliyeti ölçülebiliyorsa:

$$M = M_0 + \sum_{h=1}^{L} g_h \sqrt{n_h}$$

g_h: gezi maliyeti. Birimler bir alana dağıldığında aralarındaki ortalama uzaklık, alan sabitken yaklaşık $\sqrt{n_h}$ ile büyür.

TRÖ Varyansının Yararlı Bir Yazılışı

Önceki dersten:

$$\mathrm{V}(\bar{y}_{tb}) = \sum_{h=1}^{L} W_h^2 (1 - f_h) \frac{S_h^2}{n_h}, \qquad W_h = \frac{N_h}{N},\ f_h = \frac{n_h}{N_h}.$$

$(1 - f_h)/n_h = 1/n_h - 1/N_h$ olduğundan

$$\mathrm{V}(\bar{y}_{tb}) = \sum_{h=1}^{L} \frac{W_h^2 S_h^2}{n_h} - \sum_{h=1}^{L} \frac{W_h^2 S_h^2}{N_h} = \sum_{h=1}^{L} \frac{W_h^2 S_h^2}{n_h} - \frac{1}{N} \sum_{h=1}^{L} W_h S_h^2$$

- İkinci terim n_h'lere **bağlı değildir**; dağıtım yalnızca birinci terimi etkiler.
- Dolayısıyla eniyileme problemi: $\sum_h \frac{W_h^2 S_h^2}{n_h}$ ifadesini bir kısıt altında en küçüklemek.

İçerik

1 Dağıtım Problemi ve Maliyet Fonksiyonu

2 En İyi (Optimum) Dağıtım

3 Neyman, Orantılı ve Eşit Dağıtım

4 Uygulamada Karşılaşılan Sorunlar

5 TRÖ'de Örneklem Büyüklüğü (Ortalama ve Toplam)

6 Oran Tahmini İçin Dağıtım ve Örneklem Büyüklüğü

7 Çözümlü Problemler

8 R ile Uygulama

9 Özet ve Alıştırmalar

Teorem: En İyi Dağıtım

Teorem 1 (Optimum dağıtım)

$M = M_0 + \sum_{h=1}^{L} m_h n_h$ maliyet fonksiyonuna sahip TRÖ'de, tabaka örneklem büyüklüğü

$$n_h \propto \frac{N_h S_h}{\sqrt{m_h}} \qquad \textit{yani} \qquad \boxed{n_h = n \frac{N_h S_h / \sqrt{m_h}}{\sum_{k=1}^{L} N_k S_k / \sqrt{m_k}}}$$

olduğunda $\bar{y}_{tb}$'nin varyansı (verilen maliyet için) en küçük olur. Aynı dağıtım, verilen varyans için maliyeti de en küçük yapar.

Üç sezgisel kural

Bir tabakadan **daha çok** birim seçilir, eğer tabaka

1. daha **büyükse** (N_h büyük),
2. daha **değişkense** (S_h büyük),
3. birim başına **daha ucuzsa** (m_h küçük).

İspat: Lagrange Çarpanları Yöntemi

$M - M_0 = \sum_h m_h n_h$ kısıtı altında $\mathrm{V}(\bar{y}_{tb})$ en küçüklenecektir. Lagrange fonksiyonu:

$$\mathcal{L} = \sum_{h=1}^{L} \frac{W_h^2 S_h^2}{n_h} - \sum_{h=1}^{L} \frac{W_h^2 S_h^2}{N_h} + \lambda\Big(\sum_{h=1}^{L} m_h n_h - M + M_0\Big)$$

n_h'ye göre türev alıp sıfıra eşitleyelim:

$$\frac{\partial \mathcal{L}}{\partial n_h} = -\frac{W_h^2 S_h^2}{n_h^2} + \lambda m_h = 0 \quad \Longrightarrow \quad n_h\sqrt{\lambda} = \frac{W_h S_h}{\sqrt{m_h}}, \qquad h = 1, \ldots, L.$$

Tüm tabakalar üzerinden toplanırsa:

$$n\sqrt{\lambda} = \sum_{h=1}^{L} \frac{W_h S_h}{\sqrt{m_h}}.$$

İki eşitlik oranlanırsa (λ yok olur):

$$\frac{n_h}{n} = \frac{W_h S_h/\sqrt{m_h}}{\sum_k W_k S_k/\sqrt{m_k}} = \frac{N_h S_h/\sqrt{m_h}}{\sum_k N_k S_k/\sqrt{m_k}}. \qquad \blacksquare$$

Alternatif İspat: Cauchy–Schwarz Eşitsizliği

$V' = \sum_h W_h^2 S_h^2 / n_h$ ve $C' = M - M_0 = \sum_h m_h n_h$ olsun. Çarpımlarını inceleyelim:

$$V' \cdot C' = \Big(\sum_h \frac{W_h^2 S_h^2}{n_h}\Big)\Big(\sum_h m_h n_h\Big) \;\geq\; \Big(\sum_h \frac{W_h S_h}{\sqrt{n_h}} \cdot \sqrt{m_h n_h}\Big)^2 = \Big(\sum_h W_h S_h \sqrt{m_h}\Big)^2.$$

- Sağ taraf n_h'lere bağlı değildir: $V'C'$ çarpımının **alt sınırı**dır.
- Eşitlik, vektörler orantılı olduğunda sağlanır:

$$\frac{W_h S_h / \sqrt{n_h}}{\sqrt{m_h n_h}} = \text{sabit} \iff n_h \propto \frac{W_h S_h}{\sqrt{m_h}}.$$

- C' sabitse V' en küçük; V' sabitse C' en küçük olur. Aynı dağıtım **her iki** problemi birden çözer.

Sonuç

Optimum dağıtımda: $V'_{\min} \cdot C' = \Big(\sum_h W_h S_h \sqrt{m_h}\Big)^2$

Gezi Maliyeti Altında En İyi Dağıtım

Maliyet fonksiyonu $M = M_0 + \sum_h g_h\sqrt{n_h}$ ise

$$\mathcal{L} = \sum_h \frac{W_h^2 S_h^2}{n_h} + \lambda\Big(\sum_h g_h\sqrt{n_h} - M + M_0\Big)$$

$$\frac{\partial \mathcal{L}}{\partial n_h} = -\frac{W_h^2 S_h^2}{n_h^2} + \frac{\lambda g_h}{2\sqrt{n_h}} = 0 \implies n_h^{3/2} = \frac{2}{\lambda}\cdot\frac{W_h^2 S_h^2}{g_h}$$

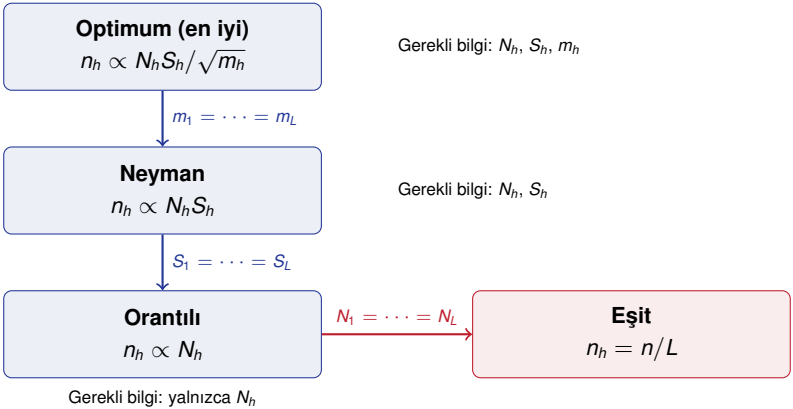
$$\boxed{n_h = n\,\frac{\left(N_h^2 S_h^2/g_h\right)^{2/3}}{\sum_{k=1}^{L}\left(N_k^2 S_k^2/g_k\right)^{2/3}}}$$

Doğrusal maliyetle karşılaştırıldığında dağıtım, $N_h S_h$'ye göre **daha hızlı** büyür ($N_h S_h$ yerine $(N_h S_h)^{4/3}$), çünkü ek birimlerin marjinal gezi maliyeti azalır.

İçerik

1. Dağıtım Problemi ve Maliyet Fonksiyonu
2. En İyi (Optimum) Dağıtım
3. Neyman, Orantılı ve Eşit Dağıtım
4. Uygulamada Karşılaşılan Sorunlar
5. TRÖ'de Örneklem Büyüklüğü (Ortalama ve Toplam)
6. Oran Tahmini İçin Dağıtım ve Örneklem Büyüklüğü
7. Çözümlü Problemler
8. R ile Uygulama
9. Özet ve Alıştırmalar

Özel Durumlar: Dağıtım Hiyerarşisi



Her alt düzey, üstündekinin bir varsayım altındaki özel halidir. Varsayım gerçekte sağlanmıyorsa alt düzeydeki dağıtım **daha büyük varyans** verir.

Neyman ve Orantılı Dağıtım

Neyman dağıtımı (tabakalar arası birim maliyeti eşit: $m_h = m$)

$$n_h = n \frac{N_h S_h}{\sum_{k=1}^{L} N_k S_k} = n \frac{W_h S_h}{\sum_k W_k S_k}$$

Verilen n için varyansı en küçük yapar. (Neyman, 1934; Tschuprow, 1923)

Orantılı dağıtım (maliyet ve standart sapma eşit: $S_h = S$)

$$n_h = n \frac{N_h}{\sum_{k=1}^{L} N_k} = n \frac{N_h}{N} = nW_h \qquad (f_h = f)$$

Yalnızca N_h bilgisi gerekir; örneklem **kendi kendini ağırlıklandırır**: $\bar{y}_{tb} = \bar{y}$.

Eşit dağıtım: $n_h = n/L$

Maliyet, standart sapma ve tabaka büyüklüğünü dikkate almadığından genellikle tercih edilmez. Ancak amaç her tabaka için **ayrı ve eşit duyarlılıkta tahmin** ise (ör. illerin karşılaştırılması) uygun olabilir.

Her Dağıtımda Varyans

$(1 - f_h)$ terimleri dahil, n_h yerine yazılarak:

Dağıtım	$\mathrm{V}(\bar{y}_{tb})$
Orantılı	$\frac{1-f}{n}\sum_h W_h S_h^2$
Neyman	$\frac{1}{n}\Big(\sum_h W_h S_h\Big)^2 - \frac{1}{N}\sum_h W_h S_h^2$
Optimum	$\frac{1}{n}\Big(\sum_h W_h S_h \sqrt{m_h}\Big)\Big(\sum_h \frac{W_h S_h}{\sqrt{m_h}}\Big) - \frac{1}{N}\sum_h W_h S_h^2$
Eşit	$\frac{L}{n}\sum_h W_h^2 S_h^2 - \frac{1}{N}\sum_h W_h S_h^2$

Dağıtımların Karşılaştırılması

Teorem 2

Aynı toplam n için (N_h'ler büyük):

$$\mathrm{V}_{Neyman}(\bar{y}_{tb}) \;\le\; \mathrm{V}_{orn}(\bar{y}_{tb}) \;\le\; \mathrm{V}_{BR}(\bar{y}).$$

Kesin farklar:

$$\mathrm{V}_{orn} - \mathrm{V}_{Ney} = \frac{1}{n}\sum_h W_h\big(S_h - \bar{S}\big)^2, \qquad \bar{S} = \sum_h W_h S_h$$

$$\mathrm{V}_{BR} - \mathrm{V}_{orn} \approx \frac{1-f}{n}\sum_h W_h\big(\bar{Y}_h - \bar{Y}\big)^2$$

İspat (ilk fark). $\sum W_h S_h^2 - \big(\sum W_h S_h\big)^2 = \sum W_h (S_h - \bar{S})^2$ (ağırlıklı varyans özdeşliği) ve $(1-f)/n = 1/n - 1/N$. ■

Yorum

- Orantılının BRÖ'ye kazancı: tabaka **ortalamaları** farklıysa.
- Neyman'ın orantılıya kazancı: tabaka **standart sapmaları** farklıysa.

İçerik

1. Dağıtım Problemi ve Maliyet Fonksiyonu
2. En İyi (Optimum) Dağıtım
3. Neyman, Orantılı ve Eşit Dağıtım
4. Uygulamada Karşılaşılan Sorunlar
5. TRÖ'de Örneklem Büyüklüğü (Ortalama ve Toplam)
6. Oran Tahmini İçin Dağıtım ve Örneklem Büyüklüğü
7. Çözümlü Problemler
8. R ile Uygulama
9. Özet ve Alıştırmalar

Sorun 1: $n_h > N_h$ (Aşırı Örnekleme)

Neyman ya da optimum dağıtım, küçük ama çok değişken bir tabakaya kendi büyüklüğünden fazla birim atayabilir.

Örnek 1

$N_1 = 50$, $S_1 = 100$ *(büyük işletmeler);* $N_2 = 950$, $S_2 = 5$*;* $n = 200$*, Neyman dağıtımı.*

$$N_1 S_1 = 5000, \quad N_2 S_2 = 4750 \;\Rightarrow\; n_1 = 200 \cdot \frac{5000}{9750} = 102.6 > N_1 = 50\ !$$

Çözüm: tamamı sayılan tabaka

1. $n_h > N_h$ olan tabakalarda $n_h = N_h$ alınır (tam sayım; bu tabakanın varyansa katkısı 0).
2. Kalan örneklem ($n - \sum N_h$) diğer tabakalara aynı kuralla yeniden dağıtılır.
3. Yeni dağıtımda yine taşma olursa işlem tekrarlanır.

Örnekte: $n_1 = 50$, kalan 150 birim $\Rightarrow n_2 = 150$.

Diğer Pratik Sorunlar

Yuvarlama

n_h tam sayı olmalıdır. En yakın tam sayıya yuvarlanır; $\sum n_h = n$ sağlanmazsa kesir kısmı en büyük olan tabaka(lar) bir artırılır. Yuvarlama varyansı pratik olarak değiştirmez.

Her tabakada $n_h \geq 2$

Varyans tahmini için gereklidir. Dağıtım $n_h < 2$ veriyorsa $n_h = 2$ alınır.

S_h bilinmiyor

Önceki araştırmalar, pilot çalışma, benzer bir değişken ya da sayım verileri kullanılır. S_h'lerdeki orta düzeyde hatalar varyansı çok az artırır: optimum dağıtım "düz bir tepe"dedir (flat optimum).

Birden çok değişken

Her değişken farklı bir Neyman dağıtımı ister. Uzlaşma yolları: orantılı dağıtım, en önemli değişkene göre dağıtım ya da dağıtımların ortalaması.

İçerik

1. Dağıtım Problemi ve Maliyet Fonksiyonu
2. En İyi (Optimum) Dağıtım
3. Neyman, Orantılı ve Eşit Dağıtım
4. Uygulamada Karşılaşılan Sorunlar
5. TRÖ'de Örneklem Büyüklüğü (Ortalama ve Toplam)
6. Oran Tahmini İçin Dağıtım ve Örneklem Büyüklüğü
7. Çözümlü Problemler
8. R ile Uygulama
9. Özet ve Alıştırmalar

İki Soru

Tabakalara dağıtım belirlendikten sonra toplam n'ye geçilir:

1. **Verilen maliyet** için varyansı en küçük kılan örneklem büyüklüğü
2. **Verilen varyans** (ya da hoşgörü) için maliyeti en küçük kılan örneklem büyüklüğü

Hatırlatma: istenen varyans

Hoşgörü d ve güven katsayısı t ise istenen varyans

$$V = \left(\frac{d}{t}\right)^2$$

(Kaynak çözümlerde bu değer $D^2 = d^2/z^2$ ile de gösterilmiştir.)

Verilen Maliyet İçin Örneklem Büyüklüğü

$M = M_0 + \sum_h m_h n_h$ maliyet fonksiyonunda optimum dağıtım

$$n_h = n \frac{N_h S_h / \sqrt{m_h}}{\sum_k N_k S_k / \sqrt{m_k}}$$

yerine yazılırsa:

$$M - M_0 = n \frac{\sum_h m_h N_h S_h / \sqrt{m_h}}{\sum_h N_h S_h / \sqrt{m_h}} = n \frac{\sum_h N_h S_h \sqrt{m_h}}{\sum_h N_h S_h / \sqrt{m_h}}$$

$$\boxed{n = \frac{(M - M_0) \sum_{h=1}^{L} N_h S_h / \sqrt{m_h}}{\sum_{h=1}^{L} N_h S_h \sqrt{m_h}}}$$

- Bütçenin değişken kısmı $(M - M_0)$, "ortalama birim maliyete" bölünür.
- $m_h = m$ ise $n = (M - M_0)/m$: beklenen sonuç.

Verilen Varyans İçin Örneklem Büyüklüğü: Genel Form

$n_h = n\,k_h$ şeklinde bir dağıtım yapıldığını varsayalım ($\sum k_h = 1$). k_h: optimum, Neyman, orantılı, eşit ya da araştırmacının belirlediği herhangi bir pay olabilir.

$$\mathrm{V}(\bar{y}_{tb}) = \frac{1}{n}\sum_h \frac{W_h^2 S_h^2}{k_h} - \frac{1}{N}\sum_h W_h S_h^2 = V$$

n'ye göre çözülürse:

$$\boxed{n = \frac{\sum_h W_h^2 S_h^2/k_h}{V + \frac{1}{N}\sum_h W_h S_h^2}} \qquad \text{ya da} \qquad n_0 = \frac{1}{V}\sum_h \frac{W_h^2 S_h^2}{k_h}, \quad n = \frac{n_0}{1 + \frac{1}{NV}\sum_h W_h S_h^2}$$

Uygulamada S_h^2 bilinmediğinden ön tahminleri s_h^2 kullanılır. n_0: düzeltme terimi ihmal edildiğinde ilk yaklaşım.

Dağıtıma Göre Örneklem Büyüklüğü: Ortalama

Dağıtım	k_h	n
Optimum	$\dfrac{W_h S_h/\sqrt{m_h}}{\sum W_h S_h/\sqrt{m_h}}$	$\dfrac{\left(\sum W_h S_h\sqrt{m_h}\right)\left(\sum W_h S_h/\sqrt{m_h}\right)}{V+\frac{1}{N}\sum W_h S_h^2}$
Neyman	$\dfrac{W_h S_h}{\sum W_h S_h}$	$\dfrac{\left(\sum W_h S_h\right)^2}{V+\frac{1}{N}\sum W_h S_h^2}$
Orantılı	W_h	$n_0=\dfrac{\sum W_h S_h^2}{V}, \quad n=\dfrac{n_0}{1+n_0/N}$

N'lerle yazılış (kaynak çözümlerde kullanılan)

Pay ve payda N^2 ile çarpılırsa, ör. optimum için:

$$n=\frac{\left(\sum N_h S_h\sqrt{m_h}\right)\left(\sum N_h S_h/\sqrt{m_h}\right)}{N^2V+\sum N_h S_h^2}, \qquad n_{orn}=\frac{N\sum N_h S_h^2}{N^2V+\sum N_h S_h^2}$$

Toplam Tahmini İçin Örneklem Büyüklüğü

Kitle toplamı için $\mathrm{V}(\hat{Y}_{tb}) = N^2\mathrm{V}(\bar{y}_{tb})$ olduğundan, toplam için istenen varyans V_T ise:

$$\mathrm{V}(\hat{Y}_{tb}) = \frac{1}{n}\sum_h \frac{N_h^2 S_h^2}{k_h} - \sum_h N_h S_h^2 = V_T \implies n = \frac{\sum_h N_h^2 S_h^2/k_h}{V_T + \sum_h N_h S_h^2}$$

Dağıtım	n
Optimum	$\dfrac{\left(\sum N_h S_h \sqrt{m_h}\right)\left(\sum N_h S_h/\sqrt{m_h}\right)}{V_T + \sum N_h S_h^2}$
Neyman	$\dfrac{\left(\sum N_h S_h\right)^2}{V_T + \sum N_h S_h^2}$
Orantılı	$n_0 = \dfrac{N}{V_T}\sum N_h S_h^2, \quad n = \dfrac{n_0}{1 + n_0/N}$

Denklik: ortalama için V ile toplam için $V_T = N^2 V$ aynı n'yi verir.

İçerik

1. Dağıtım Problemi ve Maliyet Fonksiyonu
2. En İyi (Optimum) Dağıtım
3. Neyman, Orantılı ve Eşit Dağıtım
4. Uygulamada Karşılaşılan Sorunlar
5. TRÖ'de Örneklem Büyüklüğü (Ortalama ve Toplam)
6. Oran Tahmini İçin Dağıtım ve Örneklem Büyüklüğü
7. Çözümlü Problemler
8. R ile Uygulama
9. Özet ve Alıştırmalar

Kesikli Veriler İçin En İyi Dağıtım

0–1 değişkeninde tabaka varyansı:

$$S_h^2 = \frac{N_h P_h Q_h}{N_h - 1} \cong P_h Q_h \qquad (N_h \cong N_h - 1)$$

$M = M_0 + \sum_h m_h n_h$ maliyet fonksiyonu altında:

Optimum dağıtım

$$n_h = n \frac{N_h \sqrt{P_h Q_h / m_h}}{\sum_k N_k \sqrt{P_k Q_k / m_k}}$$

Neyman dağıtımı ($m_h = m$)

$$n_h \cong n \frac{N_h \sqrt{P_h Q_h}}{\sum_k N_k \sqrt{P_k Q_k}}$$

Önemli gözlem

$\sqrt{PQ}$, $P \in [0.3,\ 0.7]$ aralığında yalnızca 0.46–0.50 arasında değişir. Bu nedenle tabaka oranları çok farklı değilse (ör. biri 0.05, diğeri 0.5 değilse) Neyman dağıtımı orantılıdan **çok az** farklıdır ve kazancı küçüktür.

Oran İçin Örneklem Büyüklüğü

$n_h \cong n_h - 1$ yaklaşımı altında, istenen varyans V için:

$$n = \frac{\sum_h W_h^2 P_h Q_h / k_h}{V + \frac{1}{N}\sum_h W_h P_h Q_h}$$

Dağıtım	n
Optimum	$\dfrac{\left(\sum W_h \sqrt{P_h Q_h m_h}\right)\left(\sum W_h \sqrt{P_h Q_h / m_h}\right)}{V + \frac{1}{N}\sum W_h P_h Q_h}$
Neyman	$n_0 = \dfrac{\left(\sum W_h \sqrt{P_h Q_h}\right)^2}{V}, \quad n = \dfrac{n_0}{1 + \frac{1}{NV}\sum W_h P_h Q_h}$
Orantılı	$n_0 = \dfrac{\sum W_h P_h Q_h}{V}, \quad n = \dfrac{n_0}{1 + n_0/N}$

P_h bilinmediğinden ön çalışmadan gelen p_h değerleri kullanılır; hiç bilgi yoksa $P_h = 0.5$ (en kötü durum).

İçerik

1. Dağıtım Problemi ve Maliyet Fonksiyonu
2. En İyi (Optimum) Dağıtım
3. Neyman, Orantılı ve Eşit Dağıtım
4. Uygulamada Karşılaşılan Sorunlar
5. TRÖ'de Örneklem Büyüklüğü (Ortalama ve Toplam)
6. Oran Tahmini İçin Dağıtım ve Örneklem Büyüklüğü
7. Çözümlü Problemler
8. R ile Uygulama
9. Özet ve Alıştırmalar

Problem 1 (Özdemir, 2015, Soru 11): Veriler

Üç bölgeye ayrılan bir şehirde hane başına ortalama gelir tahmin edilmek isteniyor.

Bölge	s_h	N_h	c_h (birim maliyet)	$N_h s_h^2$
1	400	1150	1	184 000 000
2	600	2120	4	763 200 000
3	800	930	9	595 200 000
		$N = 4200$	Toplam:	1 542 400 000

Hane başına ortalama gelir için %95 güven aralığının tahminin iki yanında **50$** kadar uzanması isteniyor.

$$V = \frac{d^2}{z^2} = \frac{50^2}{1.96^2} = 650.77$$

(a) Orantılı dağıtıma göre her bölgeden kaç birim seçilmelidir?

(b) En uygun (optimum) dağıtıma göre her bölgeden kaç birim seçilmelidir?

(c) İki tasarımın maliyetlerini karşılaştırınız.

Problem 1 (a): Orantılı Dağıtım

$$n = \frac{N \sum N_h s_h^2}{N^2 V + \sum N_h s_h^2} = \frac{4200\,(1\,542\,400\,000)}{4200^2\,(650.77) + 1\,542\,400\,000} = 497.47 \;\Rightarrow\; n = 497$$

$n_h = \dfrac{N_h}{N}\, n$:

$$n_1 = \frac{1150}{4200}497 = 136.1 \to 136, \quad n_2 = \frac{2120}{4200}497 = 250.9 \to 251, \quad n_3 = \frac{930}{4200}497 = 110.1 \to 110$$

Kontrol

Bu dağıtımla $\mathrm{V}(\bar{y}_{tb}) = \sum W_h^2 (1 - f_h) s_h^2 / n_h = 651.5 \approx V$ ✓
Güven aralığının yarı genişliği: $1.96\sqrt{651.5} = 50.03$\$.

Problem 1 (b): Optimum Dağıtım

Bölge	s_h	c_h	N_h	$N_h s_h$	$N_h s_h \sqrt{c_h}$	$N_h s_h / \sqrt{c_h}$	$N_h s_h^2$
1	400	1	1150	460 000	460 000	460 000	184 000 000
2	600	4	2120	1 272 000	2 544 000	636 000	763 200 000
3	800	9	930	744 000	2 232 000	248 000	595 200 000
				2 476 000	5 236 000	1 344 000	1 542 400 000

$$n = \frac{\left(\sum N_h s_h \sqrt{c_h}\right)\left(\sum N_h s_h / \sqrt{c_h}\right)}{N^2 V + \sum N_h s_h^2} = \frac{5\,236\,000\,(1\,344\,000)}{4200^2(650.77) + 1\,542\,400\,000} = 540.4 \;\Rightarrow\; n = 540$$

$$n_1 = \frac{460\,000}{1\,344\,000}540 = 185, \qquad n_2 = \frac{636\,000}{1\,344\,000}540 = 255, \qquad n_3 = \frac{248\,000}{1\,344\,000}540 = 100$$

Problem 1 (c): Maliyet Karşılaştırması

$$C_{orn} = \sum c_h n_h = 1(136) + 4(251) + 9(110) = 2130$$

$$C_{opt} = \sum c_h n_h = 1(185) + 4(255) + 9(100) = 2105$$

Yorum

- Her iki tasarım **aynı duyarlılığı** sağlar: $\mathrm{V}(\bar{y}_{tb}) \approx 650.8$.
- Optimum dağıtım, toplam örneklem daha büyük olmasına rağmen ($540 > 497$) daha ucuzdur: pahalı 3. bölgeden (birim maliyet 9) daha az, ucuz 1. bölgeden daha çok birim seçer.
- Neyman dağıtımı (c_h dikkate alınmadan) aynı duyarlılık için $n = 471$ verir: $n_h = 87, 242, 142$. Birim sayısı en az olan tasarımdır, ama maliyeti $1(87) + 4(242) + 9(142) = 2333$ olur!

Ders

"En küçük n" ile "en küçük maliyet" aynı şey değildir. Birim maliyetleri farklıysa optimum dağıtım kullanılmalıdır.

Problem 1 (Ek): Sabit $n = 500$ İçin Dört Dağıtım

Aynı verilerle $n = 500$ sabit tutulursa:

Dağıtım	n_1	n_2	n_3	$\mathrm{V}(\bar{y}_{tb})$	$\mathrm{sh}(\bar{y}_{tb})$	Maliyet
Eşit	166.7	166.7	166.7	723.1	26.89	2333
Orantılı	136.9	252.4	110.7	647.0	25.44	2143
Neyman	92.9	256.9	150.2	607.6	24.65	2473
Optimum	171.1	236.6	92.3	710.4	26.65	1948

- n sabitken **en küçük varyans Neyman**'dadır (tanımı gereği).
- Optimum dağıtım n sabitken değil, **maliyet sabitken** en iyidir; burada en ucuz tasarımdır.
- $\mathrm{V}_{orn} - \mathrm{V}_{Ney} = 647.0 - 607.6 = 39.4 = \frac{1}{n}\sum W_h(S_h - \bar{S})^2$ ✓ ($\bar{S} = 589.5$)

Bütçe verilirse

$M - M_0 = 2000$ için optimum: $n = \dfrac{2000\,(1\,344\,000)}{5\,236\,000} = 513.4$; $n_h \approx 176, 243, 95$; $\mathrm{V} = 689.7$. Aynı bütçeyle orantılı dağıtım ($n = 466.7$) $\mathrm{V} = 699.5$ verir.

Problem 2 (Özdemir, 2015, Soru 15): Kütüphane Kullanımı

3 fakülteli bir üniversitede geçen yıl en az bir kez kütüphaneye giden öğrencilerin oranı araştırılıyor: $N_A = 2500$, $N_B = 1500$, $N_C = 1000$, $N = 5000$.

(a) 200 öğrenci seçilecek; orantılı dağıtım:

$$n_A = \frac{2500}{5000}200 = 100, \qquad n_B = \frac{1500}{5000}200 = 60, \qquad n_C = \frac{1000}{5000}200 = 40$$

Örneklem sonuçları: $p_A = 0.2$, $p_B = 0.4$, $p_C = 0.3$.

(b) Oran için 2σ'lık güven aralığı:

$$p_{tb} = \frac{2500(0.2) + 1500(0.4) + 1000(0.3)}{5000} = 0.28$$

$$\hat{\mathrm{V}}(p_{tb}) = \frac{1}{N^2}\sum_h N_h^2 \frac{N_h - n_h}{N_h}\frac{p_h q_h}{n_h - 1} = 0.000388 + 0.000351 + 0.000207 = 0.000946$$

$$0.28 \mp 2\sqrt{0.000946} = 0.28 \mp 0.0615 \;\Rightarrow\; 0.218 < P < 0.342$$

Orantılı dağıtımda $n_h = nN_h/N$ yazılırsa: $\hat{\mathrm{V}}(p_{orn}) = \dfrac{N-n}{N^2}\displaystyle\sum_h \frac{N_h^2\, p_h q_h}{N_h n - N}$ (aynı sonuç).

Problem 2 (c): Orantılı Dağıtımla Örneklem Büyüklüğü

$z = 2$ ve $d = 0.04$ isteniyor: $V = d^2/z^2 = 0.0004$.

Fakülte	p_h	q_h	N_h	$p_h q_h$	$N_h p_h q_h$
A	0.2	0.8	2500	0.16	400
B	0.4	0.6	1500	0.24	360
C	0.3	0.7	1000	0.21	210
				Toplam:	970

$$n = \frac{N \sum N_h p_h q_h}{N^2 V + \sum N_h p_h q_h} = \frac{5000\,(970)}{5000^2(0.0004) + 970} = 442.1 \;\Rightarrow\; n = 442$$

$$n_A = 221, \quad n_B = 133, \quad n_C = 88$$

200 birimlik pilot çalışma yapıldığından $442 - 200 = 242$ birim daha seçilmelidir: A'dan 121, B'den 73, C'den 48.

Problem 2 (d): Optimum Dağıtımla Örneklem Büyüklüğü

$z = 2$, $d = 0.02 \Rightarrow V = 0.0001$; birim maliyetler $c_A = 1$, $c_B = 2$, $c_C = 3$.

Fakülte	p_h	N_h	c_h	$N_h\sqrt{p_h q_h}/\sqrt{c_h}$	$N_h\sqrt{p_h q_h}\sqrt{c_h}$	$N_h p_h q_h$
A	0.2	2500	1	1000.00	1000.00	400
B	0.4	1500	2	519.62	1039.23	360
C	0.3	1000	3	264.58	793.73	210
				1784.19	2832.96	970

$$n = \frac{2832.96\,(1784.19)}{5000^2(0.0001) + 970} = \frac{5\,054\,528}{3470} = 1456.6 \;\Rightarrow\; n = 1457$$

$$n_A = \frac{1000}{1784.19}1457 = 817, \quad n_B = \frac{519.62}{1784.19}1457 = 424, \quad n_C = \frac{264.58}{1784.19}1457 = 216$$

Pilot üzerine ek: A'dan 717, B'den 364, C'den 176 birim. Maliyet: $817 + 2(424) + 3(216) = 2313$.

Problem 3 (Özdemir, 2015, Soru 16): Geciken Hesaplar

Bir mağazalar zincirinin 3 tabakası var; ödemesi 2 hafta ya da daha fazla gecikmiş hesapların oranı tahmin edilecek. $z = 3$, $d = 0.03 \Rightarrow V = 0.0001$; Neyman dağıtımı.

Mağaza	p_h	q_h	N_h	$N_h\sqrt{p_h q_h}$	$N_h p_h q_h$
A	0.4	0.6	2000	979.80	480
B	0.3	0.7	3000	1374.77	630
C	0.6	0.4	5000	2449.49	1200
			10 000	4804.06	2310

$$n = \frac{\left(\sum N_h\sqrt{p_h q_h}\right)^2}{N^2 V + \sum N_h p_h q_h} = \frac{4804.06^2}{10\,000^2(0.0001) + 2310} = 1874.8 \Rightarrow n = 1875$$

$$n_A = \frac{979.80}{4804.06}1875 = 382, \quad n_B = \frac{1374.77}{4804.06}1875 = 537, \quad n_C = \frac{2449.49}{4804.06}1875 = 956$$

Karşılaştırma

Orantılı dağıtımla gereken örneklem $n = 1876.5$'tir. $\sqrt{p_h q_h}$ değerleri (0.49, 0.46, 0.49) birbirine çok yakın olduğundan Neyman'ın kazancı yalnızca **2 birimdir**.

İçerik

1. Dağıtım Problemi ve Maliyet Fonksiyonu
2. En İyi (Optimum) Dağıtım
3. Neyman, Orantılı ve Eşit Dağıtım
4. Uygulamada Karşılaşılan Sorunlar
5. TRÖ'de Örneklem Büyüklüğü (Ortalama ve Toplam)
6. Oran Tahmini İçin Dağıtım ve Örneklem Büyüklüğü
7. Çözümlü Problemler
8. R ile Uygulama
9. Özet ve Alıştırmalar

R: Dağıtım Fonksiyonu

```
dagit <- function(n, Nh, Sh = rep(1, length(Nh)), mh = rep(1, length(Nh)),
                  yontem = c("optimum", "neyman", "orantili", "esit")) {
  yontem <- match.arg(yontem)
  a <- switch(yontem,
              optimum  = Nh * Sh / sqrt(mh),
              neyman   = Nh * Sh,
              orantili = Nh,
              esit     = rep(1, length(Nh)))
  nh <- n * a / sum(a)
  # n_h > N_h ise tabakayi tamamen al, kalani yeniden dagit
  tam <- rep(FALSE, length(Nh))
  while (any(nh > Nh & !tam)) {
    tam <- tam | nh > Nh
    kalan <- n - sum(Nh[tam])
    nh[tam] <- Nh[tam]
    nh[!tam] <- kalan * a[!tam] / sum(a[!tam])
  }
  nh
}
dagit(200, Nh = c(50, 950), Sh = c(100, 5), yontem = "neyman")  # 50 150
```

R: Yardımcı Fonksiyonlar

```
yuvarla <- function(x) {        # toplami koruyarak yuvarlama
  f <- floor(x); k <- round(sum(x)) - sum(f)
  i <- order(x - f, decreasing = TRUE)[seq_len(k)]
  f[i] <- f[i] + 1; f
}
V_tro <- function(nh, Nh, Sh) {
  Wh <- Nh / sum(Nh)
  sum(Wh^2 * (1 - nh / Nh) * Sh^2 / nh)
}

# Ornek: toplami koruyarak yuvarlama
yuvarla(c(87.504, 241.968, 141.528))   # 87 242 142  (toplam 471)
round(c(87.504, 241.968, 141.528))     # 88 242 142  (toplam 472!)
```

Basit `round()` toplamı bozabilir. `yuvarla()` önce aşağı yuvarlar, eksik kalan birimleri kesir kısmı en büyük olan tabakalara ekler.

R: Örneklem Büyüklüğü ve Problem 1

```
n_tro <- function(V, Nh, Sh, mh = rep(1, length(Nh)),
                  yontem = c("optimum", "neyman", "orantili")) {
  yontem <- match.arg(yontem)
  N <- sum(Nh); Wh <- Nh / N
  payda <- V + sum(Wh * Sh^2) / N
  pay <- switch(yontem,
    optimum  = sum(Wh * Sh * sqrt(mh)) * sum(Wh * Sh / sqrt(mh)),
    neyman   = sum(Wh * Sh)^2,
    orantili = sum(Wh * Sh^2))
  pay / payda
}
Nh <- c(1150, 2120, 930); Sh <- c(400, 600, 800); ch <- c(1, 4, 9)
V  <- (50 / 1.96)^2
for (y in c("orantili", "neyman", "optimum")) {
  n  <- round(n_tro(V, Nh, Sh, ch, y))
  nh <- yuvarla(dagit(n, Nh, Sh, ch, y))
  cat(sprintf("%-9s n = %4d  nh = %s  maliyet = %5d  V = %.1f\n",
              y, n, paste(nh, collapse = ","), sum(ch * nh),
              V_tro(nh, Nh, Sh)))
}
# orantili n = 497  nh = 136,251,110  maliyet = 2130  V = 651.5
# neyman    n = 471  nh = 87,242,142   maliyet = 2333  V = 650.4
# optimum   n = 540  nh = 185,255,100  maliyet = 2105  V = 650.9
```

İçerik

1. Dağıtım Problemi ve Maliyet Fonksiyonu
2. En İyi (Optimum) Dağıtım
3. Neyman, Orantılı ve Eşit Dağıtım
4. Uygulamada Karşılaşılan Sorunlar
5. TRÖ'de Örneklem Büyüklüğü (Ortalama ve Toplam)
6. Oran Tahmini İçin Dağıtım ve Örneklem Büyüklüğü
7. Çözümlü Problemler
8. R ile Uygulama
9. Özet ve Alıştırmalar

Özet

	Optimum	Neyman	Orantılı
$n_h \propto$	$N_h S_h / \sqrt{m_h}$	$N_h S_h$	N_h
Ne zaman?	m_h farklı	m_h eşit, S_h farklı	S_h benzer / bilinmiyor
En iyi olduğu durum	maliyet sabit	n sabit	–
Gerekli bilgi	N_h, S_h, m_h	N_h, S_h	N_h
Ağırlıklar	farklı	farklı	eşit (self-weighting)

- Verilen bütçe: $n = \dfrac{(M - M_0) \sum N_h S_h / \sqrt{m_h}}{\sum N_h S_h \sqrt{m_h}}$
- Verilen varyans: $n = \dfrac{\sum W_h^2 S_h^2 / k_h}{V + \frac{1}{N} \sum W_h S_h^2}$, oran için $S_h^2 \to P_h Q_h$
- Sıralama (n sabit): $\mathrm{V}_{Ney} \leq \mathrm{V}_{orn} \leq \mathrm{V}_{BR}$

Alıştırmalar

1. $N_h = 400,\ 600,\ 1000$; $S_h = 10,\ 20,\ 5$; $n = 100$. Orantılı ve Neyman dağıtımını bulup $\mathrm{V}(\bar{y}_{tb})$'leri karşılaştırınız. Farkın $\frac{1}{n}\sum W_h(S_h - \bar{S})^2$'ye eşit olduğunu doğrulayınız.
2. 1. alıştırmada birim maliyetler $m_h = 4,\ 9,\ 1$ ve değişken bütçe $M - M_0 = 600$ ise optimum n ve n_h'leri bulunuz.
3. $N_h = 20,\ 480$; $S_h = 200,\ 10$; $n = 60$ için Neyman dağıtımını uygulayınız. Ne sorunla karşılaşırsınız, nasıl çözersiniz?
4. İki tabaka: $N_h = 3000,\ 2000$; ön çalışmadan $p_h \approx 0.1,\ 0.5$. Oranı %95 güvenle ± 0.03 hoşgörüyle tahmin etmek için Neyman ve orantılı dağıtımla gereken n ve n_h'leri bulunuz.
5. Optimum dağıtımın hem "verilen maliyet için varyansı" hem "verilen varyans için maliyeti" en küçüklediğini Cauchy–Schwarz eşitsizliği ile açıklayınız.

Alıştırmalar: Cevap Anahtarı

1. Orantılı: $n_h = 20, 30, 50$, $\mathrm{V} = 1.4488$. Neyman: $N_h S_h = 4000, 12000, 5000 \Rightarrow n_h = 19.0,\ 57.1,\ 23.8$, $\mathrm{V} = 1.0262$. $\bar{S} = 9.5$; $\frac{1}{100}\sum W_h(S_h - \bar{S})^2 = 0.4225 = 1.4488 - 1.0262$ ✓
2. $\sum N_h S_h/\sqrt{m_h} = 2000 + 4000 + 5000 = 11\,000$; $\sum N_h S_h\sqrt{m_h} = 8000 + 36\,000 + 5000 = 49\,000$; $n = 600(11\,000)/49\,000 = 134.7$; $n_h = 24.5,\ 49.0,\ 61.2$ (yuvarlanarak $24, 49, 61$ veya bütçeyi aşmayacak biçimde); $\mathrm{V} = 0.924$.
3. $N_h S_h = 4000, 4800 \Rightarrow n_1 = 27.3 > N_1 = 20$. 1. tabaka tamamen alınır ($n_1 = 20$), kalan 40 birim 2. tabakaya: $n_2 = 40$.
4. $V = (0.03/1.96)^2 = 0.000234$.
   Neyman: $N_h\sqrt{p_h q_h} = 900, 1000$; $n = 544.7 \to 545$; $n_h = 258,\ 287$.
   Orantılı: $\sum N_h p_h q_h = 770$; $n = 581.0 \to 581$; $n_h = 349,\ 232$. Neyman %6 daha küçük örneklem ister.
5. $V'C' \geq (\sum W_h S_h\sqrt{m_h})^2$ alt sınırı n_h'den bağımsızdır ve eşitlik $n_h \propto W_h S_h/\sqrt{m_h}$ iken sağlanır; biri sabitken diğeri bu sınıra iner.

Ders Kitapları ve Kaynaklar

- Özdemir, Y., Şahin Tekin, S. T., Esin, A. A. (2015). *Çözümlü Örneklerle Örnekleme Yöntemlerine Giriş*, 1. Baskı.
- Esin, A., Bakır, M. A., Aydın, C., Gürbüzsel, E. (2010). *Temel Örnekleme Yöntemleri – Taro Yamane*, 3. Baskı.
- Zeybek, M. *Örnekleme Ders Notları*.
- Cochran, W. G. (1977). *Sampling Techniques*, 3rd ed. Wiley. (Bölüm 5.5–5.10)
- Neyman, J. (1934). On the two different aspects of the representative method. *JRSS*, 97, 558–625.
- Lohr, S. L. (2022). *Sampling: Design and Analysis*, 3rd ed. CRC Press. (Bölüm 3.4)