İST347 · İstatistiksel Analiz Uygulamaları

ARA SINAV · DENEME KİTAPÇIĞI B (Çalışma Amaçlı)

Süre: 75 dakika · Cevap anahtarı ve özet ayrı kâğıttadır (İST347_Cevap_ve_Ozet.pdf). Önce bakmadan çözün.

Ad Soyad:		Öğrenci No:	

Bölüm	I Çoktan seçmeli	II Doğru/Yanlış	III Kod/Hata	IV Grafik yorumlama	Toplam
Puan	30	20	6	44	100
Aldığı					

Sorular, ders notlarındaki konulara ve duyurulan sınav kapsamına göre hazırlanmış özgün deneme sorularıdır; gerçek sınavın soruları değildir.

Bölüm I · Çoktan seçmeli (15 soru × 2 puan = 30)

1. `x <- c(2, 5, 8, 11)` tanımından sonra `x[-1]` ifadesinin çıktısı nedir?

A) 2 5 8
B) 5 8 11
C) 2
D) 11

2. `class(c(1L, 2.5, TRUE))` ifadesinin çıktısı nedir?

A) "integer"
B) "numeric"
C) "logical"
D) "character"

3. Aşağıdaki kodu çalıştırınca `Error: object 'veri' not found` hatası alınıyor. Hatanın nedeni nedir?

```
df <- read.csv("satis.csv")
ortalama <- mean(veri$fiyat)
```

A) satis.csv dosyası çalışma dizininde yok
B) fiyat sütunu sayısal değil
C) veri adında bir nesne oluşturulmamış (okunan veri df adına atanmış)
D) mean() fonksiyonu için paket yüklenmemiş

4. `ggplot(df, aes(x, y))` yazan öğrenci `Error in ggplot(): could not find function "ggplot"` hatası alıyor. Doğru çözüm hangisidir?

A) install.packages("ggplot")
B) ggplot2 paketini her çalıştırmadan önce yeniden kurmak
C) aes() içine colour eklemek
D) library(ggplot2) komutunu çalıştırmak

5. `x <- c(5, 12, 8)` için `ifelse(x > 6, x * 2, 0)` ifadesinin çıktısı nedir?

A) 0 24 16
B) 10 24 16
C) 0 12 8
D) Hata verir

6. Bir Quarto kod parçasının **çalışmasını** ama ne kodun ne de çıktının belgede **görünmemesini** istiyorsunuz. Hangi seçenek kullanılır?

A) #| eval: false
B) #| echo: false
C) #| include: false
D) #| warning: false

7. Noktaları *ada* (`island`) göre renklendirmek istiyorsunuz. Boşluğa ne yazılmalıdır?
`ggplot(penguins, aes(bill_length_mm, body_mass_g)) + geom_point(_____)`

A) colour = island

B) colour = "island"

C) aes(colour = "island")

D) aes(colour = island)

8. `sapply(list(a = 1:3, b = 4:6), mean)` ifadesinin çıktısı nedir?

A) Elemanları a ve b olan bir liste

B) İsimli bir sayısal vektör: a = 2, b = 5

C) 2 × 3 boyutlu bir matris

D) Hata verir

9. `m <- matrix(1:6, nrow = 2)` için `apply(m, 1, sum)` ifadesinin çıktısı nedir?

A) 9 12

B) 6 15

C) 3 7 11

D) 21

10. Bir veride ortalama 18, ortanca 25 bulunmuştur. Dağılım ve raporlanması gereken merkezi ölçü için hangisi doğrudur?

A) Sağa çarpık; ortalama

B) Sola çarpık; ortalama

C) Sola çarpık; ortanca

D) Simetrik; ikisi de

11. `A <- c(48, 50, 52, 50, 50)` ve `B <- c(30, 45, 50, 55, 70)` için hangisi doğrudur? (İki grubun ortalaması da 50'dir.)

A) İkisinin değişkenliği aynıdır, çünkü ortalamalar eşittir

B) A daha değişkendir

C) Değişkenlik karşılaştırılamaz

D) B daha değişkendir; standart sapması ve açıklığı daha büyüktür

12. Bir değişkende Q1 = 30 ve Q3 = 50'dir. Tukey (1,5 × ÇAG) kuralına göre aşağıdakilerden hangisi aykırı değerdir?

A) 82

B) 80

C) 5

D) 78

13. `fivenum(c(1, 3, 5, 7, 9, 11, 13))` ifadesinin çıktısı nedir?

A) 1 3 7 11 13

B) 1 5 7 9 13

C) 1 4 7 10 13

D) 1 3 5 7 9

14. Veri çerçevesindeki **bütün satırları koruyarak** yeni bir sütun eklemek için hangi dplyr fonksiyonu kullanılır?

A) summarise()

B) mutate()

C) filter()

D) select()

15. Bir Excel dosyası **noktalı virgülle** ayrılmış ve ondalık ayırıcısı **virgül** olacak şekilde CSV olarak kaydedilmiştir. Okumak için hangisi uygundur?

A) read.csv("d.csv")

B) read.csv2("d.csv")

C) read.table("d.csv", sep = ",")

D) readLines("d.csv")

Bölüm II · Doğru / Yanlış (10 ifade × 2 puan = 20)

İfade doğru ise **D**, yanlış ise **Y** yazınız.

No	İfade	D/Y
1	`matrix(1:6, nrow = 2)[1, ]` ifadesinin sonucu `1 2 3`'tür.	
2	`sd()` fonksiyonu varyansı hesaplarken paydada $n - 1$ kullanır.	
3	Ortalama aykırı değerlerden etkilenir; ortanca aykırı değerlere karşı dayanıklıdır.	
4	`library(ggplot2)` komutu paketi bilgisayara kurar.	
5	`#| eval: false` seçeneği kodu belgeden gizler ancak çıktıyı gösterir.	
6	`df$x` ile `df[["x"]]` aynı türde (vektör) sonuç verir.	
7	`if (c(TRUE, FALSE)) ...` yazımı R 4.2 ve sonrasında hata verir.	
8	Simpson paradoksunda birleşik veride görülen ilişki, gruplar ayrı ayrı incelendiğinde aynen korunur.	
9	Dört veri kümesinin ortalama, standart sapma ve korelasyonu aynıysa grafikleri de aynı görünür.	
10	`geom_point(colour = "red")` bütün noktaları kırmızı yapar.	

Bölüm III · Kod ve hata mesajı yorumlama (3 soru × 2 puan = 6)

K1. Aşağıdaki kodun çıktısında bütün ortalamalar `NA` çıkmıştır. Nedenini ve düzeltmeyi yazınız.

```
penguins |> group_by(species) |>
  summarise(ort = mean(bill_length_mm))
#> species   ort
#> Adelie     NA
#> Chinstrap  NA
#> Gentoo     NA
```

K2. Aşağıdaki hata mesajını yorumlayınız: hata nerede, neden oluştu, nasıl düzeltilir?

```
library(tidyvrse)
#> Error in library(tidyvrse) : there is no package called 'tidyvrse'
```

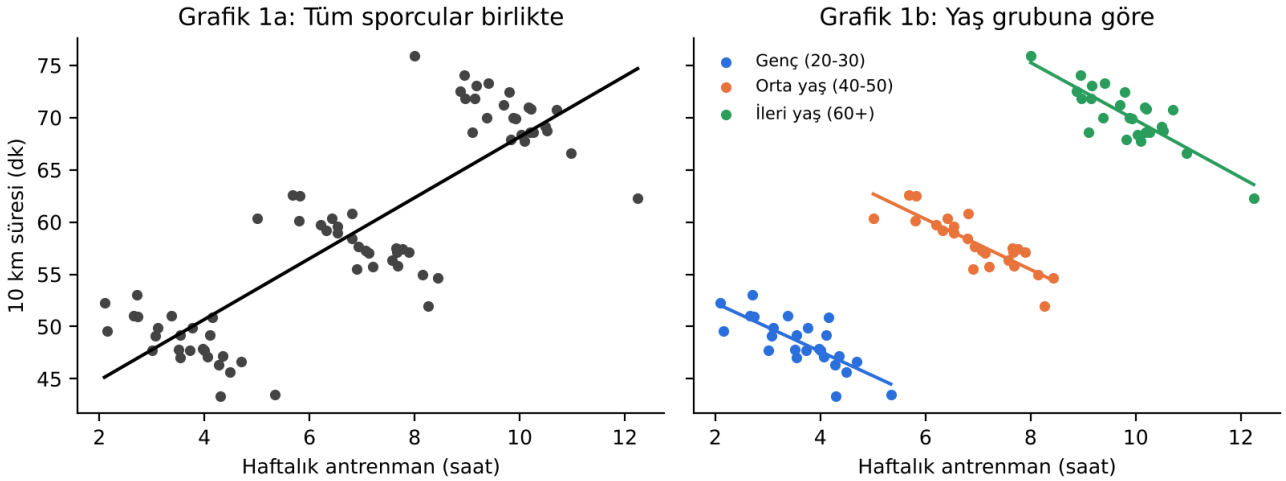
K3. Aşağıdaki grafikte noktalar mavi olmayıp varsayılan bir renkte çıkıyor ve yanında “blue” yazan bir gösterge beliriyor. Neden? Nasıl düzeltilir?

```
ggplot(penguins, aes(bill_length_mm, body_mass_g)) +
  geom_point(aes(colour = "blue"))
```

Bölüm IV · Grafik yorumlama (44 puan)

Grafik Yorumlama 1 · Antrenman ve 10 km süresi (16 puan)

75 koşucunun haftalık antrenman süresi (saat) ve 10 km koşu süresi (dakika) ölçülmüştür. Koşucular üç yaş grubundadır. Grafik 1a bütün koşucuları birlikte, Grafik 1b yaş grubuna göre gösterir; çizgiler doğrusal regresyon doğrularıdır.




```
ggplot(kosucu, aes(x = saat, y = sure, ______ = yas_grubu)) +
  geom_point() +
  geom_smooth(method = "lm", se = FALSE)
```

(a) Grafik 1a'ya göre antrenman süresi ile 10 km süresi arasındaki ilişkiyi (yön ve güç) yorumlayınız. (3 puan)

(b) Grafik 1b'de her yaş grubu kendi içinde incelendiğinde ilişkinin yönü nedir? (a) ile karşılaştırınız. (3 puan)

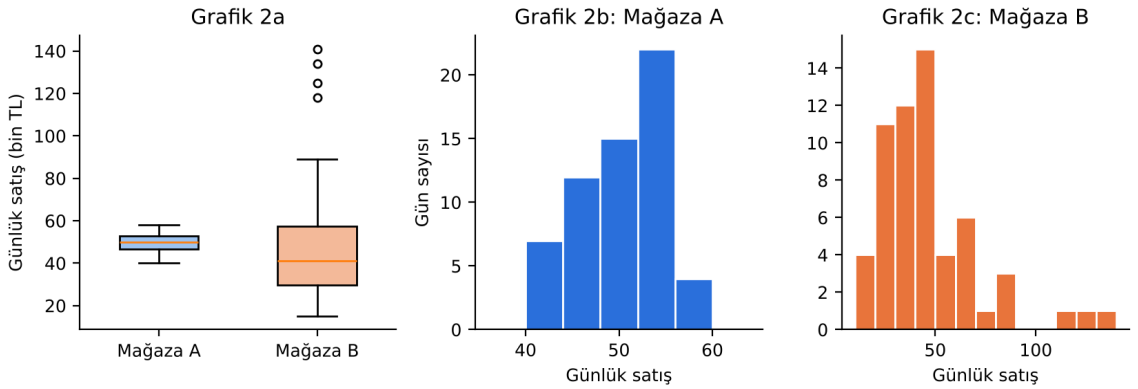
(c) Bu çelişkinin nedenini, yaş gruplarının antrenman saati ve koşu süresi bakımından konumlarına dayanarak açıklayınız. (4 puan)

(d) Bu duruma ne ad verilir? Karıştırıcı (gizli) değişken hangisidir? (3 puan)

(e) Koddaki boşluğa ne yazılmalıdır? Bu eşleme neden `aes()` içinde yapılır? (3 puan)

Grafik Yorumlama 2 · İki mağazanın günlük satışları (14 puan)

İki mağazanın 60 günlük günlük satışları (bin TL) kutu grafiği ve histogramlarla gösterilmiştir. Özet değerler:



	Min	Q1	Ortanca	Q3	Maks	Ortalama	Std. sapma
Mağaza A	40	46,75	50	53	58	49,7	4,46
Mağaza B	15	29,75	41	57,5	141	47,8	27,9

(a) Hangi mağazanın satışları daha değişkendir? Tablodan üç ölçüyle gerekçelendiriniz. (3 puan)

(b) Mağaza B'nin dağılım şeklini yorumlayınız. Bu mağazanın tipik günlük satışı için hangi merkezi ölçü raporlanmalıdır? (3 puan)

(c) Mağaza B için Tukey (1,5 × ÇAG) sınırlarını hesaplayınız. Grafikte görünen uç noktalar aykırı değer midir? (4 puan)

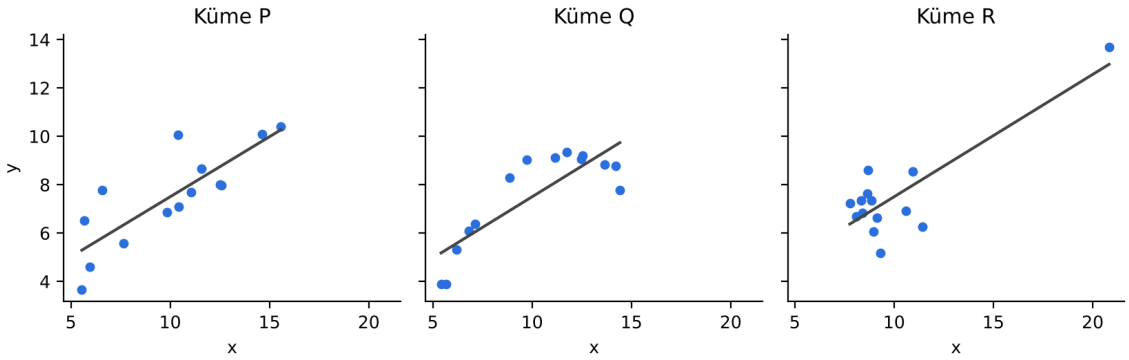
(d) Aykırı değerlerden ortalama mı ortanca mı daha çok etkilenmiştir? Tablodan kanıtlayınız. (2 puan)

(e) Kutu grafiğinde kutunun içindeki kalın çizgi neyi gösterir? (2 puan)

Grafik Yorumlama 3 · Üç veri kümesi (14 puan)

Her biri 14 gözlemden oluşan üç x–y kümesinin özetleri ve grafikleri aşağıdadır.

Küme	ort_x	ort_y	sd_x	sd_y	r	Regresyon doğrusu
P	10	7,5	3,3	2,0	0,82	y = 2,5 + 0,5x
Q	10	7,5	3,3	2,0	0,84	y = 2,5 + 0,5x
R	10	7,5	3,3	2,0	0,83	y = 2,5 + 0,5x



(a) Yalnızca özet tabloya bakan biri P, Q ve R hakkında ne düşünür? (3 puan)

(b) Grafiğe göre hangi küme(ler)de ilişkiyi bir doğruyla özetlemek uygun değildir? Her biri için nedenini bir cümleyle yazınız. (4 puan)

(c) R kümesinde sağ üstteki tek nokta çıkarılırsa korelasyon yaklaşık kaç olur (0'a yakın / 0,8 civarı / −1'e yakın)? Bu nokta için hangi terim kullanılır? (3 puan)

(d) Q kümesi için doğrusal model yerine nasıl bir model düşünülebilir? (2 puan)

(e) Bu örnekten bir veri analizinde izlenecek sıra açısından hangi ders çıkarılır? (2 puan)

— Sınav bitti. Başarılar. —