İST347 Dönem Ödevi — Veri Havuzu

30 veri seti: kura ile her gruba bir tane

İçindekiler

1. Doğum ağırlığı 3

2. 1993 otomobilleri 3

3. Öğrenci anketi 4

4. Melanom hastaları 4

5. Hollanda ilkokulları 5

6. Pima kadınlarında diyabet 5

7. Akademisyen maaşları 6

8. Ontario ücretleri 6

9. Dünya ülkeleri 7

10. Mesleklerin saygınlığı 7

11. Şili 1988 referandumu 8

12. ABD'de kelime bilgisi 8

13. Uyma davranışı deneyi 9

14. ABD ücret anketi 1985 9

15. Kaliforniya okulları 10

16. Ders değerlendirmeleri ve görünüş 11

17. Yaşlılarda doktor ziyaretleri 11

18. İsviçre'de kadın işgücü 12

19. Windsor'da ev fiyatları 12

20. Ames ev satışları 13

21. Çalışan ayrılması 13

22. Kredi başvuruları 14

23. Telekom müşteri kaybı **14**

24. Yazılımcı maaşları **15**

25. Sacramento emlak satışları **15**

26. Araçların yakıt tüketimi **16**

27. Ortabatı ilçeleri **16**

28. Memelilerin uykusu **17**

29. Star Wars karakterleri **17**

30. Kahvaltılık gevrekler **18**

Her gruba aşağıdaki veri setlerinden biri **kura ile** atanır. Bütün veri setlerinde ödevde istenen analizlerin (iki grup karşılaştırması, ANOVA, ki-kare testi, regresyon) yapılabildiği ders sorumlusu tarafından kontrol edilmiştir.

Her veri seti için verilen **önerilen roller** yalnızca bir başlangıç noktasıdır:

Rol	Kullanıldığı analiz
Y (sayısal)	Ana değişken: betimsel istatistik, testlerin bağımlı değişkeni, regresyonda yanıt
X (sayısal)	Regresyonda açıklayıcı değişken
G2 (2 düzeyli)	t-testi ve Mann–Whitney U testi
G3 (3+ düzeyli)	ANOVA ve Kruskal–Wallis testi
K1 × **K2**	Ki-kare bağımsızlık testi

Adı **italik** yazılan değişkenler veride doğrudan bulunmaz, sizin **türetmeniz** gerekir ("Türetilecekler" satırına bakın). Gerekçesini yazmak koşuluyla başka değişkenler de seçebilirsiniz.

Paketleri bir kez kurun:

```
install.packages(c("MASS", "carData", "AER", "modeldata", "ggplot2", "dplyr"))
```

Özet Liste

No	Veri	Alan	Paket	n	Eksik
1	Doğum ağırlığı	Sağlık	MASS	189	Yok
2	1993 otomobilleri	Otomotiv	MASS	93	Var
3	Öğrenci anketi	Eğitim / Sağlık	MASS	237	Var
4	Melanom hastaları	Sağlık	MASS	205	Yok
5	Hollanda ilkokulları	Eğitim	MASS	2287	Yok
6	Pima kadınlarında diyabet	Sağlık	MASS	300	Var
7	Akademisyen maaşları	Ekonomi / Eğitim	carData	397	Yok
8	Ontario ücretleri	Ekonomi	carData	7425	Var
9	Dünya ülkeleri	Demografi	carData	213	Var
10	Mesleklerin saygınlığı	Sosyoloji	carData	102	Var
11	Şili 1988 referandumu	Siyaset bilimi	carData	2700	Var
12	ABD'de kelime bilgisi	Eğitim / Sosyoloji	carData	1888	Var
13	Uyma davranışı deneyi	Psikoloji	carData	45	Yok
14	ABD ücret anketi 1985	Ekonomi	AER	534	Yok

No	Veri	Alan	Paket	n	Eksik
15	Kaliforniya okulları	Eğitim	AER	420	Yok
16	Ders değerlendirmeleri ve görünüş	Eğitim	AER	463	Yok
17	Yaşlılarda doktor ziyaretleri	Sağlık ekonomisi	AER	4406	Yok
18	İsviçre'de kadın işgücü	Ekonomi	AER	872	Yok
19	Windsor'da ev fiyatları	Emlak	AER	546	Yok
20	Ames ev satışları	Emlak	modeldata	2930	Yok
21	Çalışan ayrılması	İnsan kaynakları	modeldata	1470	Yok
22	Kredi başvuruları	Finans	modeldata	4454	Var
23	Telekom müşteri kaybı	Pazarlama	modeldata	7043	Var
24	Yazılımcı maaşları	Bilişim	modeldata	5594	Yok
25	Sacramento emlak satışları	Emlak	modeldata	932	Yok
26	Araçların yakıt tüketimi	Otomotiv	ggplot2	234	Yok
27	Ortabatı ilçeleri	Demografi	ggplot2	437	Yok
28	Memelilerin uykusu	Biyoloji	ggplot2	83	Var
29	Star Wars karakterleri	Eğlence (kirli veri)	dplyr	87	Var
30	Kahvaltılık gevrekler	Beslenme	MASS	65	Yok

1. Doğum ağırlığı

Alan: Sağlık · **Boyut:** 189 gözlem × 10 değişken · **Eksik hücre:** 0

ABD'de Baystate Tıp Merkezi'nde (Springfield, 1986) doğan 189 bebeğin doğum ağırlığı ve annelerine ait risk etmenleri.

```
veri <- MASS::birthwt
```

Değişken	Açıklama
`bwt`	Doğum ağırlığı (g)
`lwt`	Annenin son adet dönemindeki ağırlığı (pound)
`age`	Annenin yaşı
`smoke`	Hamilelikte sigara (0 = hayır, 1 = evet)
`race`	Irk (1 = beyaz, 2 = siyah, 3 = diğer)
`low`	Düşük doğum ağırlığı (< 2500 g; 0/1)
`ht`	Hipertansiyon öyküsü (0/1)
`ftv`	İlk üç aydaki doktor ziyareti sayısı

Önerilen roller: Y = `bwt` · X = `lwt` · G2 = `smoke` · G3 = `race` · K1 × K2 = `smoke` × `low`

Türetilecekler: Kategorik değişkenler 0/1/2/3 gibi sayılarla kodlanmıştır; `factor()` ile anlamlı etiketli faktörlere çevirin.

Dikkat: Sayı ile kodlanmış kategorik değişkenler.

2. 1993 otomobilleri

Alan: Otomotiv · **Boyut:** 93 gözlem × 27 değişken · **Eksik hücre:** 13

1993'te ABD'de satılan 93 otomobil modelinin fiyat ve teknik özellikleri.

```
veri <- MASS::Cars93
```

Değişken	Açıklama
`Price`	Ortalama fiyat (1000 $)
`Horsepower`	Beygir gücü
`MPG.city`	Şehir içi yakıt verimi (mil/galon)
`Origin`	Üretim yeri (USA / non-USA)
`DriveTrain`	Çekiş (4WD / Front / Rear)
`AirBags`	Hava yastığı (None / Driver only / Driver & Passenger)
`Type`	Gövde tipi (6 düzey)
`Weight`	Ağırlık (pound)

Önerilen roller: Y = `Price` · X = `Horsepower` · G2 = `Origin` · G3 = `DriveTrain` · K1 × K2 = `Origin` × `AirBags`

Türetilecekler: Gerekmez.

Dikkat: Bazı sütunlarda eksik değer var; fiyat sağa çarpık.

3. Öğrenci anketi

Alan: Eğitim / Sağlık · **Boyut:** 237 gözlem × 12 değişken · **Eksik hücre:** 107

Adelaide Üniversitesi'nde 237 istatistik öğrencisinden toplanan anket verisi.

```
veri <- MASS::survey
```

Değişken	Açıklama
`Height`	Boy (cm)
`Wr.Hnd`	Yazan elin karış uzunluğu (cm)
`Pulse`	Nabız (vuruş/dk)
`Sex`	Cinsiyet
`Exer`	Egzersiz sıklığı (Freq / Some / None)
`Smoke`	Sigara (Heavy / Regul / Occas / Never)
`Age`	Yaş
`W.Hnd`	Yazan el (Left / Right)

Önerilen roller: Y = `Height` · X = `Wr.Hnd` · G2 = `Sex` · G3 = `Exer` · K1 × K2 = `Sex` × `Smoke`

Türetilecekler: Gerekmez.

Dikkat: Pek çok değişkende eksik değer var; Exer düzeylerinin sırası anlamlı değil, düzenleyin.

4. Melanom hastaları

Alan: Sağlık · **Boyut:** 205 gözlem × 7 değişken · **Eksik hücre:** 0

Danimarka'da 1962–1977 arasında kötü huylu melanom ameliyatı olan 205 hasta.

```
veri <- MASS::Melanoma
```

Değişken	Açıklama
`thickness`	Tümör kalınlığı (mm)
`age`	Ameliyattaki yaş
`time`	Takip süresi (gün)
`ulcer`	Ülserleşme (1 = var, 0 = yok)
`sex`	Cinsiyet (1 = erkek, 0 = kadın)
`status`	Durum (1 = melanomdan öldü, 2 = yaşıyor, 3 = başka nedenle öldü)
`year`	Ameliyat yılı

Önerilen roller: Y = `thickness` · X = `age` · G2 = `ulcer` · G3 = `status` · K1 × K2 = `sex` × `ulcer`

Türetilecekler: Kategorik değişkenler sayı ile kodlanmıştır; `factor()` ile etiketleyin.

Dikkat: Tümör kalınlığı çok sağa çarpık; parametrik olmayan testler önemli.

5. Hollanda ilkokulları

Alan: Eğitim · **Boyut:** 2287 gözlem × 6 değişken · **Eksik hücre:** 0

Hollanda'da 133 sınıftaki 2287 sekizinci sınıf öğrencisinin dil testi puanları.

```
veri <- MASS::nlschools
```

Değişken	Açıklama
`lang`	Dil testi puanı
`IQ`	Sözel IQ
`SES`	Ailenin sosyoekonomik düzeyi (puan)
`COMB`	Birleştirilmiş sınıf mı? (0 = hayır, 1 = evet)
`GS`	Sınıf mevcudu
`class`	Sınıf kimliği

Önerilen roller: Y = `lang` · X = `IQ` · G2 = `COMB` · G3 = *SES_grup* · K1 × K2 = `COMB` × *SES_grup*

Türetilecekler: `SES` değişkeninden `cut()` ile 3 düzeyli bir sosyoekonomik düzey faktörü (Düşük/Orta/Yüksek) türetin.

Dikkat: Büyük örneklem: hemen her fark anlamlı çıkar; etki büyüklüğüne odaklanın.

6. Pima kadınlarında diyabet

Alan: Sağlık · **Boyut:** 300 gözlem × 8 değişken · **Eksik hücre:** 114

ABD'nin Arizona eyaletinde yaşayan, 21 yaşından büyük 300 Pima kökenli kadında diyabet ve ilgili ölçümler.

```
veri <- MASS::Pima.tr2
```

Değişken	Açıklama
`glu`	Plazma glikoz derişimi
`bmi`	Beden kitle indeksi
`bp`	Diyastolik kan basıncı (mm Hg)
`age`	Yaş
`npreg`	Gebelik sayısı
`skin`	Triseps deri kıvrım kalınlığı (mm)
`type`	Diyabet (Yes / No)
`ped`	Diyabet soyağacı işlevi

Önerilen roller: Y = `glu` · X = `bmi` · G2 = `type` · G3 = *yas_grup* · K1 × K2 = `type` × *yas_grup*

Türetilecekler: `age` değişkeninden `cut()` ile en az 3 düzeyli bir yaş grubu faktörü türetin.

Dikkat: Eksik değerler var (özellikle skin, bp).

7. Akademisyen maaşları

Alan: Ekonomi / Eğitim · **Boyut:** 397 gözlem × 6 değişken · **Eksik hücre:** 0

ABD'de bir üniversitedeki 397 öğretim üyesinin 2008–2009 dokuz aylık maaşları.

```
veri <- carData::Salaries
```

Değişken	Açıklama
`salary`	Dokuz aylık maaş ($)
`yrs.since.phd`	Doktoradan bu yana geçen yıl
`yrs.service`	Hizmet yılı
`rank`	Unvan (AsstProf / AssocProf / Prof)
`discipline`	Alan (A = kuramsal, B = uygulamalı)
`sex`	Cinsiyet

Önerilen roller: Y = `salary` · X = `yrs.since.phd` · G2 = `sex` · G3 = `rank` · K1 × K2 = `sex` × `rank`

Türetilecekler: Gerekmez.

Dikkat: Kadın öğretim üyesi sayısı az; grup büyüklüklerine dikkat.

8. Ontario ücretleri

Alan: Ekonomi · **Boyut:** 7425 gözlem × 5 değişken · **Eksik hücre:** 3648

Kanada'nın Ontario eyaletinde 1994 yılında yapılan gelir ve çalışma anketi (7425 kişi).

```
veri <- carData::SLID
```

Değişken	Açıklama
`wages`	Saatlik ücret ($)
`education`	Eğitim yılı
`age`	Yaş
`sex`	Cinsiyet
`language`	Ana dil (English / French / Other)

Önerilen roller: Y = `wages` · X = `education` · G2 = `sex` · G3 = `language` · K1 × K2 = `sex` × `language`

Türetilecekler: Gerekmez.

Dikkat: Ücret değişkeninin yaklaşık yarısı eksik; eksik verinin nasıl ele alındığını tartışın.

9. Dünya ülkeleri

Alan: Demografi · **Boyut:** 213 gözlem × 7 değişken · **Eksik hücre:** 90

Birleşmiş Milletler'in 213 ülke ve bölge için 2009–2011 istatistikleri.

```
veri <- carData::UN
```

Değişken	Açıklama
`infantMortality`	Bebek ölüm hızı (1000 canlı doğumda)
`lifeExpF`	Kadınlarda doğumda beklenen yaşam süresi
`ppgdp`	Kişi başına GSYH ($)
`fertility`	Doğurganlık hızı
`pctUrban`	Kentsel nüfus yüzdesi
`group`	Ülke grubu (oecd / africa / other)
`region`	Bölge (8 düzey)

Önerilen roller: Y = `lifeExpF` · X = *log_gdp* · G2 = *kentsel* · G3 = `group` · K1 × K2 = `group` × *kentsel*

Türetilecekler: `pctUrban` değişkeninden 2 düzeyli bir kentleşme faktörü (%50 kentsel / değil) türetin. Kişi başı GSYH çok çarpık olduğu için regresyonda logaritmasını kullanın.

Dikkat: Eksik değerler var; ülke adları satır adlarında.

10. Mesleklerin saygınlığı

Alan: Sosyoloji · **Boyut:** 102 gözlem × 6 değişken · **Eksik hücre:** 4

Kanada'da 1971'de 102 mesleğin saygınlık puanı, ortalama eğitim ve gelir düzeyleri.

```
veri <- carData::Prestige
```

Değişken	Açıklama
`prestige`	Pineo-Porter saygınlık puanı
`income`	Ortalama gelir ($)
`education`	Ortalama eğitim yılı
`women`	Kadın çalışan yüzdesi
`type`	Meslek türü (bc = mavi yaka, wc = beyaz yaka, prof = profesyonel)

Önerilen roller: Y = `prestige` · X = `education` · G2 = *kadin_agirlikli* · G3 = `type` · K1 × K2 = `type` × *kadin_agirlikli*

Türetilecekler: `women` değişkeninden 2 düzeyli bir faktör (kadın ağırlıklı meslek: %50 / değil) türetin.

Dikkat: Küçük örneklem; `type` değişkeninde 4 eksik değer var. Meslek adları satır adlarında.

11. Şili 1988 referandumu

Alan: Siyaset bilimi · **Boyut:** 2700 gözlem × 8 değişken · **Eksik hücre:** 295

Şili'de 1988 Pinochet referandumu öncesinde yapılan 2700 kişilik kamuoyu araştırması.

```
veri <- carData::Chile
```

Değişken	Açıklama
`statusquo`	Mevcut rejimi destekleme ölçeği (yüksek = destek)
`age`	Yaş
`income`	Aylık gelir (peso)
`sex`	Cinsiyet
`education`	Eğitim (P = ilk, S = orta, PS = yüksek)
`vote`	Oy niyeti (Y = evet, N = hayır, U = kararsız, A = katılmayacak)
`region`	Bölge (5 düzey)

Önerilen roller: Y = `statusquo` · X = `age` · G2 = `sex` · G3 = `education` · K1 × K2 = `sex` × `vote`

Türetilecekler: Gerekmez.

Dikkat: Eksik değerler var; eğitim düzeylerinin sırasını düzenleyin.

12. ABD'de kelime bilgisi

Alan: Eğitim / Sosyoloji · **Boyut:** 1888 gözlem × 8 değişken · **Eksik hücre:** 45

ABD Genel Sosyal Araştırması'nın (GSS) 2016 dalgasında katılımcıların 10 soruluk kelime testi puanları.

```r
veri <- carData::GSSvocab |> dplyr::filter(year == '2016')
```

Değişken	Açıklama
`vocab`	Kelime testinde doğru sayısı (0–10)
`educ`	Eğitim yılı
`age`	Yaş
`gender`	Cinsiyet
`nativeBorn`	ABD'de doğmuş mu?
`ageGroup`	Yaş grubu (5 düzey)
`educGroup`	Eğitim grubu (5 düzey)

Önerilen roller: Y = `vocab` · X = `educ` · G2 = `gender` · G3 = `ageGroup` · K1 × K2 = `gender` × `educGroup`

Türetilecekler: Veriyi 2016 yılıyla süzerek kullanın (yükleme kodunda yapılmıştır).

Dikkat: Puan 0–10 arası tam sayı; eksik değerler var.

13. Uyma davranışı deneyi

Alan: Psikoloji · **Boyut:** 45 gözlem × 4 değişken · **Eksik hücre:** 0

45 katılımcının, yüksek ya da düşük statülü bir partnerle çalışırken partnerin yanlış kararlarına uyma sayısı.

```r
veri <- carData::Moore
```

Değişken	Açıklama
`conformity`	40 denemede partnere uyma sayısı
`fscore`	Otoriterlik (F ölçeği) puanı
`partner.status`	Partnerin statüsü (high / low)
`fcategory`	Otoriterlik düzeyi (low / medium / high)

Önerilen roller: Y = `conformity` · X = `fscore` · G2 = `partner.status` · G3 = `fcategory` · K1 × K2 = `partner.status` × `fcategory`

Türetilecekler: Gerekmez.

Dikkat: Çok küçük örneklem (n = 45): normallik ve parametrik olmayan testler önemli.

14. ABD ücret anketi 1985

Alan: Ekonomi · **Boyut:** 534 gözlem × 11 değişken · **Eksik hücre:** 0

ABD Güncel Nüfus Anketi'nin (Mayıs 1985) 534 çalışanlık örneklemi.

```r
data("CPS1985", package = "AER")
veri <- CPS1985
```

Değişken	Açıklama
`wage`	Saatlik ücret ($)
`education`	Eğitim yılı
`experience`	İş deneyimi (yıl)
`age`	Yaş
`gender`	Cinsiyet
`occupation`	Meslek (6 düzey)
`union`	Sendika üyeliği
`married`	Medeni durum
`sector`	Sektör (3 düzey)

Önerilen roller: Y = `wage` · X = `education` · G2 = `gender` · G3 = `occupation` · K1 × K2 = `gender` × `occupation`

Türetilecekler: Gerekmez.

Dikkat: Ücret sağa çarpık; log dönüşümünü tartışabilirsiniz.

15. Kaliforniya okulları

Alan: Eğitim · **Boyut:** 420 gözlem × 14 değişken · **Eksik hücre:** 0

Kaliforniya'daki 420 okul bölgesinin 1998–1999 sınav puanları ve bölge özellikleri.

```
data("CASchools", package = "AER")
veri <- CASchools
```

Değişken	Açıklama
`read`	Ortalama okuma puanı
`math`	Ortalama matematik puanı
`income`	Bölge ortalama geliri (1000 $)
`lunch`	Ücretsiz öğle yemeği alan öğrenci yüzdesi
`english`	İngilizce öğrenen öğrenci yüzdesi
`students`	Öğrenci sayısı
`teachers`	Öğretmen sayısı
`grades`	Kademe (KK-06 / KK-08)

Önerilen roller: Y = `read` · X = `income` · G2 = `grades` · G3 = *yoksulluk* · K1 × K2 = `grades` × *yoksulluk*

Türetilecekler: `lunch` değişkeninden `cut()` ile 3 düzeyli bir yoksulluk faktörü türetin. İsterseniz öğrenci/öğretmen oranını da hesaplayın.

Dikkat: Gelir ile puan ilişkisi doğrusal olmayabilir; artık grafiğine bakın.

16. Ders değerlendirmeleri ve görünüş

Alan: Eğitim · **Boyut:** 463 gözlem × 12 değişken · **Eksik hücre:** 0

Texas Üniversitesi'nde (Austin, 2000–2002) 463 dersin öğrenci değerlendirmeleri ve öğretim üyesinin görünüş puanı.

```
data("TeachingRatings", package = "AER")
veri <- TeachingRatings
```

Değişken	Açıklama
`eval`	Ders değerlendirme puanı (1–5)
`beauty`	Görünüş puanı (standartlaştırılmış)
`age`	Öğretim üyesinin yaşı
`gender`	Cinsiyet
`tenure`	Kadrolu mu?
`minority`	Azınlık mı?
`native`	Anadili İngilizce mi?
`credits`	Tek / çok kredili ders
`students`	Değerlendirmeye katılan öğrenci sayısı

Önerilen roller: Y = `eval` · X = `beauty` · G2 = `gender` · G3 = *yas_grup* · K1 × K2 = `gender` × `tenure`

Türetilecekler: `age` değişkeninden `cut()` ile en az 3 düzeyli bir yaş grubu faktörü türetin.

Dikkat: Aynı öğretim üyesinin birden çok dersi var (gözlemler tam bağımsız değil); bunu sonuçta tartışın.

17. Yaşlılarda doktor ziyaretleri

Alan: Sağlık ekonomisi · **Boyut:** 4406 gözlem × 19 değişken · **Eksik hücre:** 0

ABD Ulusal Sağlık Harcamaları Anketi (1987–1988): 66 yaş üstü 4406 kişinin doktor ziyaretleri.

```
data("NMES1988", package = "AER")
veri <- NMES1988
```

Değişken	Açıklama
`visits`	Muayenehane ziyareti sayısı
`chronic`	Kronik hastalık sayısı
`age`	Yaş (10 yıl biriminde!)
`income`	Aile geliri (10.000 $)
`school`	Eğitim yılı
`health`	Algılanan sağlık (poor / average / excellent)
`gender`	Cinsiyet
`insurance`	Özel sağlık sigortası
`married`	Evli mi?

Önerilen roller: Y = `visits` · X = `chronic` · G2 = `insurance` · G3 = `health` · K1 × K2 = `health` × `insurance`

Türetilecekler: Gerekmez. `age` değişkenini 10 ile çarparak yıla çevirmeyi unutmayın.

Dikkat: Ziyaret sayısı çok çarpık bir sayım değişkeni; büyük örneklem.

18. İsviçre'de kadın işgücü

Alan: Ekonomi · **Boyut:** 872 gözlem × 7 değişken · **Eksik hücre:** 0

İsviçre Sağlık Anketi'nde (1981) 872 kadının işgücüne katılımı ve hane özellikleri.

```
data("SwissLabor", package = "AER")
veri <- SwissLabor
```

Değişken	Açıklama
`income`	İş dışı gelirin logaritması
`age`	Yaş (10 yıl biriminde!)
`education`	Eğitim yılı
`youngkids`	7 yaşından küçük çocuk sayısı
`oldkids`	7 yaşından büyük çocuk sayısı
`participation`	İşgücüne katılıyor mu?
`foreign`	Yabancı uyruklu mu?

Önerilen roller: Y = `income` · X = `education` · G2 = `participation` · G3 = *cocuk_grup* · K1 × K2 = `participation` × `foreign`

Türetilecekler: `oldkids` değişkeninden 3 düzeyli bir faktör (0 / 1 / 2+) türetin. `age` değişkenini yıla çevirin.

Dikkat: Gelir zaten logaritması alınmış hâlde.

19. Windsor'da ev fiyatları

Alan: Emlak · **Boyut:** 546 gözlem × 12 değişken · **Eksik hücre:** 0

Kanada'nın Windsor kentinde 1987'de satılan 546 evin fiyatı ve özellikleri.

```
data("HousePrices", package = "AER")
veri <- HousePrices
```

Değişken	Açıklama
`price`	Satış fiyatı ($)
`lotsize`	Arsa büyüklüğü (feet²)
`bedrooms`	Yatak odası sayısı
`bathrooms`	Banyo sayısı
`stories`	Kat sayısı
`aircon`	Klima var mı?
`garage`	Garaj kapasitesi
`prefer`	Tercih edilen semtte mi?
`driveway`	Araba yolu var mı?

Önerilen roller: Y = `price` · X = `lotsize` · G2 = `aircon` · G3 = *kat* · K1 × K2 = `aircon` × `prefer`

Türetilecekler: `stories` değişkeninden 3 düzeyli bir kat faktörü (1 / 2 / 3+) türetin.

Dikkat: Fiyat ve arsa büyüklüğü sağa çarpık.

20. Ames ev satışları

Alan: Emlak · **Boyut:** 2930 gözlem × 74 değişken · **Eksik hücre:** 0

ABD'nin Ames (Iowa) kentinde 2006–2010 arasında satılan 2930 evin ayrıntılı özellikleri.

```
veri <- modeldata::ames
```

Değişken	Açıklama
`Sale_Price`	Satış fiyatı ($)
`Gr_Liv_Area`	Yaşam alanı (feet²)
`Year_Built`	Yapım yılı
`Central_Air`	Merkezi klima (Y / N)
`Bldg_Type`	Bina tipi (5 düzey)
`Paved_Drive`	Araba yolu kaplaması
`Neighborhood`	Semt (28 düzey)
`Overall_Cond`	Genel durum

Önerilen roller: Y = `Sale_Price` · X = `Gr_Liv_Area` · G2 = `Central_Air` · G3 = `Bldg_Type` · K1 × K2 = `Central_Air` × `Paved_Drive`

Türetilecekler: Gerekmez. 74 değişkenden çalışacaklarınızı `select()` ile seçin.

Dikkat: Çok değişkenli ve büyük veri; yaşam alanı çok büyük birkaç evde aykırı değerler var.

21. Çalışan ayrılması

Alan: İnsan kaynakları · **Boyut:** 1470 gözlem × 31 değişken · **Eksik hücre:** 0

IBM veri bilimcilerinin oluşturduğu kurgusal bir şirketin 1470 çalışanının bilgileri ve işten ayrılıp ayrılmadığı.

```
veri <- modeldata::attrition
```

Değişken	Açıklama
`MonthlyIncome`	Aylık gelir
`TotalWorkingYears`	Toplam çalışma yılı
`Age`	Yaş
`Attrition`	İşten ayrıldı mı?
`OverTime`	Fazla mesai yapıyor mu?
`Department`	Bölüm (3 düzey)
`JobSatisfaction`	İş doyumu (sıralı, 4 düzey)
`Gender`	Cinsiyet
`MaritalStatus`	Medeni durum

Değişken	Açıklama

Önerilen roller: Y = `MonthlyIncome` · X = `TotalWorkingYears` · G2 = `Attrition` · G3 = `Department` · K1 × K2 = `Attrition` × `OverTime`

Türetilecekler: Gerekmez.

Dikkat: Kurgusal veri; aylık gelir sağa çarpık.

22. Kredi başvuruları

Alan: Finans · **Boyut:** 4454 gözlem × 14 değişken · **Eksik hücre:** 455

Bir bankanın 4454 kredi başvurusu ve kredinin geri ödenip ödenmediği.

```
veri <- modeldata::credit_data
```

Değişken	Açıklama
`Amount`	İstenen kredi tutarı
`Price`	Alınacak malın fiyatı
`Income`	Gelir
`Age`	Yaş
`Seniority`	İş kıdemi (yıl)
`Status`	Kredi durumu (good / bad)
`Home`	Konut durumu (6 düzey)
`Records`	Olumsuz kredi kaydı var mı?
`Job`	İş türü (4 düzey)

Önerilen roller: Y = `Amount` · X = `Price` · G2 = `Status` · G3 = `Job` · K1 × K2 = `Status` × `Records`

Türetilecekler: Gerekmez.

Dikkat: Eksik değerler var (özellikle Income); bazı değerler aşırı.

23. Telekom müşteri kaybı

Alan: Pazarlama · **Boyut:** 7043 gözlem × 20 değişken · **Eksik hücre:** 11

Bir telekom şirketinin 7043 müşterisi ve aboneliği bırakıp bırakmadığı.

```
veri <- modeldata::wa_churn
```

Değişken	Açıklama
`monthly_charges`	Aylık ücret
	$()\|\|`tenure`\|Aboneliksresi(ay)\|\|`total_charges`\|Toplamdenen()$
`churn`	Aboneliği bıraktı mı?
`contract`	Sözleşme (aylık / 1 yıl / 2 yıl)
`internet_service`	İnternet hizmeti

Değişken	Açıklama
`payment_method`	Ödeme yöntemi
`senior_citizen`	65 yaş üstü mü? (0/1)

Önerilen roller: Y = `monthly_charges` · X = `tenure` · G2 = `churn` · G3 = `contract` · K1 × K2 = `churn` × `contract`

Türetilecekler: Gerekmez. 0/1 kodlu değişkenleri faktöre çevirin.

Dikkat: Büyük örneklem; aylık ücret iki tepeli.

24. Yazılımcı maaşları

Alan: Bilişim · **Boyut:** 5594 gözlem × 21 değişken · **Eksik hücre:** 0

Stack Overflow 2017 Geliştirici Anketi'nden 5 ülkedeki 5594 yazılımcının maaş ve çalışma bilgileri.

```
veri <- modeldata::stackoverflow
```

Değişken	Açıklama
`Salary`	Yıllık maaş ($)
`YearsCodedJob`	İşte kod yazma yılı
`CareerSatisfaction`	Kariyer memnuniyeti (0–10)
`Remote`	Uzaktan mı çalışıyor?
`Country`	Ülke (5 düzey)
`CompanySizeNumber`	Şirket büyüklüğü (çalışan)
`OpenSource`	Açık kaynağa katkı (0/1)
`Hobby`	Hobi olarak kod yazıyor mu? (0/1)

Önerilen roller: Y = `Salary` · X = `YearsCodedJob` · G2 = `Remote` · G3 = `Country` · K1 × K2 = `Remote` × `Country`

Türetilecekler: Gerekmez.

Dikkat: Büyük örneklem; ülkeler arası maaş farkı çok büyük.

25. Sacramento emlak satışları

Alan: Emlak · **Boyut:** 932 gözlem × 9 değişken · **Eksik hücre:** 0

Kaliforniya'nın Sacramento bölgesinde Mayıs 2008'de beş günde satılan 932 konut.

```
veri <- modeldata::Sacramento
```

Değişken	Açıklama
`price`	Satış fiyatı ($)
`sqft`	Alan (feet²)
`beds`	Yatak odası
`baths`	Banyo

Değişken	Açıklama
`type`	Konut tipi (Condo / Multi_Family / Residential)
`city`	Şehir (37 düzey)

Önerilen roller: Y = `price` · X = `sqft` · G2 = *buyuk_ev* · G3 = `type` · K1 × K2 = `type` × *buyuk_ev*

Türetilecekler: `beds` değişkeninden 2 düzeyli bir faktör (4+ yatak odası / değil) türetin.

Dikkat: Multi_Family grubu çok küçük.

26. Araçların yakıt tüketimi

Alan: Otomotiv · **Boyut:** 234 gözlem × 11 değişken · **Eksik hücre:** 0

1999 ve 2008 yıllarında satılan 38 popüler modelden 234 aracın yakıt verimliliği (ABD Çevre Koruma Ajansı).

```
veri <- ggplot2::mpg
```

Değişken	Açıklama
`hwy`	Otoyol yakıt verimi (mil/galon)
`cty`	Şehir içi yakıt verimi
`displ`	Motor hacmi (L)
`year`	Model yılı (1999 / 2008)
`drv`	Çekiş (f / r / 4)
`class`	Araç sınıfı (7 düzey)
`cyl`	Silindir sayısı
`manufacturer`	Üretici

Önerilen roller: Y = `hwy` · X = `displ` · G2 = `year` · G3 = `drv` · K1 × K2 = `drv` × `year`

Türetilecekler: Karakter değişkenleri ve `year` değişkenini faktöre çevirin.

Dikkat: Aynı modelin birden çok sürümü var.

27. Ortabatı ilçeleri

Alan: Demografi · **Boyut:** 437 gözlem × 28 değişken · **Eksik hücre:** 0

ABD'nin Ortabatı bölgesindeki 5 eyaletin 437 ilçesine ait nüfus sayımı göstergeleri.

```
veri <- ggplot2::midwest
```

Değişken	Açıklama
`percollege`	Üniversite mezunu yüzdesi
`percbelowpoverty`	Yoksulluk sınırı altındakilerin yüzdesi
`popdensity`	Nüfus yoğunluğu
`state`	Eyalet (IL / IN / MI / OH / WI)

Değişken	Açıklama
`inmetro`	Metropol alanında mı? (0/1)
`percwhite`	Beyaz nüfus yüzdesi

Önerilen roller: Y = `percollege` · X = `percbelowpoverty` · G2 = `inmetro` · G3 = `state` · K1 × K2 = `inmetro` × `state`

Türetilecekler: `inmetro` değişkenini faktöre çevirin.

Dikkat: Birim kişi değil ilçe; sonuçları buna göre yorumlayın.

28. Memelilerin uykusu

Alan: Biyoloji · **Boyut:** 83 gözlem × 11 değişken · **Eksik hücre:** 136

83 memeli türünün günlük uyku süresi, beslenme biçimi, beyin ve vücut ağırlıkları.

```
veri <- ggplot2::msleep
```

Değişken	Açıklama
`sleep_total`	Günlük toplam uyku (saat)
`sleep_rem`	REM uykusu (saat)
`bodywt`	Vücut ağırlığı (kg)
`brainwt`	Beyin ağırlığı (kg)
`vore`	Beslenme (carni / herbi / insecti / omni)
`order`	Takım
`conservation`	Koruma durumu

Önerilen roller: Y = `sleep_total` · X = *log_bodywt* · G2 = *boyut* · G3 = `vore` · K1 × K2 = `vore` × *boyut*

Türetilecekler: Vücut ağırlığından 2 düzeyli bir boyut faktörü (ortancadan büyük / küçük) türetin; regresyonda vücut ağırlığının logaritmasını kullanın.

Dikkat: Eksik değerler çok; vücut ağırlığı aşırı çarpık (fareden file).

29. Star Wars karakterleri

Alan: Eğlence (kirli veri) · **Boyut:** 87 gözlem × 11 değişken · **Eksik hücre:** 105

Star Wars filmlerindeki 87 karakterin boy, kütle ve diğer özellikleri.

```
veri <- dplyr::starwars |> dplyr::select(-films, -vehicles, -starships)
```

Değişken	Açıklama
`height`	Boy (cm)
`mass`	Kütle (kg)
`birth_year`	Doğum yılı (BBY)
`gender`	Toplumsal cinsiyet

Değişken	Açıklama
`sex`	Biyolojik cinsiyet
`species`	Tür (37 düzey)
`homeworld`	Gezegen
`eye_color`	Göz rengi

Önerilen roller: Y = `height` · X = `mass` · G2 = `gender` · G3 = *tur_grup* · K1 × K2 = `gender` × *tur_grup*

Türetilecekler: `species` değişkeninden 3 düzeyli bir faktör (Human / Droid / Diğer) türetin.

Dikkat: Çok kirli: eksik değerler, liste sütunları (yükleme kodunda çıkarıldı) ve aşırı bir aykırı değer (Jabba). Aykırı değerin regresyona etkisini mutlaka gösterin.

30. Kahvaltılık gevrekler

Alan: Beslenme · **Boyut:** 65 gözlem × 11 değişken · **Eksik hücre:** 0

ABD'de satılan 65 kahvaltılık gevreğin (bir porsiyon = 1 bardak) besin değerleri ve raftaki yeri.

```
veri <- MASS::UScereal
```

Değişken	Açıklama
`calories`	Kalori
`sugars`	Şeker (g)
`fibre`	Lif (g)
`protein`	Protein (g)
`fat`	Yağ (g)
`sodium`	Sodyum (mg)
`shelf`	Market rafı (1 = alt, 2 = orta, 3 = üst)
`mfr`	Üretici (G, K, N, P, Q, R)
`vitamins`	Vitamin (none / enriched / 100%)

Önerilen roller: Y = `calories` · X = `sugars` · G2 = *kellogg* · G3 = `shelf` · K1 × K2 = `shelf` × *kellogg*

Türetilecekler: `shelf` değişkenini faktöre çevirin; `mfr` değişkeninden 2 düzeyli bir faktör (Kellogg's = K / diğer) türetin.

Dikkat: Küçük örneklem; ki-kare tablosunda beklenen frekanslara dikkat.