

1.5. ÖNSEL OLASILIKLARIN BELİRLENMESİ

Kesikli durumda önsel dağılım bir olasılıklar kümesinden oluşur. Kısıtlamalar yalnızca olasılıkların eksi olmaması ve toplamın 1 olmasıdır. Bu kısıtlamalar altında istatistikçi bir önsel dağılımı nasıl belirler?

Önsel olasılıklar, ilgilenilen evren değere ilişkin önsel bilgiyi yansıtmalıdır. Bu önsel bilgi öncelikle örneklem sonuçları biçimindeyse önsel olasılıklar gözlemlenen göreceli sıklıklara (frekanslara) yakın olmalıdır.

Önceki altbölümdeki örnekte üretim yöneticisinin imalathaneden uzak kaldığını ve yapım sürecinin en son durumuyla ilgili bilgisinin az olduğunu varsayalım. Bununla birlikte, geçmişten imalatın yapım süresinin %60'ının denetim altında olduğunu; %30'u kadar x türü bozuk işleyiş, %8'si x türü ve y türü bozuk işleyiş ve yine %2'si kadar x türü, y türü ve z türü bozuk işleyiş olduğunu bilmektedir.

Eğer örneklem bilgisi yok ya da az ise, olasılıklar eldeki öteki bilgilere dayandırılmalıdır. Kalite denetimi örneğinde geçmişte sürecin %95'i denetim altında olabilir, ancak en son bilgi şimdi sürecin %60 denetim altında olduğu biçiminde olabilir. Bir istatistikçi için en son önsel olasılık seçimi öznel bir seçimdir (önsel bilgi hangi biçimi alırsa alsın). Buna göre önsel olasılıklar öznel olasılıklardır.

Daha önceden bilindiği gibi, öznel bir olasılık bir karar vericinin bir öneriye ilişkin (örneğin, $p = 0.10$ önerisi) inanç derecesini yansıtır. Ancak, eğer olasılıklar bir kişinin yargılarına dayanırsa, bu kişi yargılarını niceliklerle vermelidir (yani olasılıksal terimlerle verilmelidir).

Bir yargının niceliklerle verilmesinde sayısız teknikler vardır. Olasılık kavramını anlayan bir kişi, ilgilenilen belirsiz niceliklerin çeşitli olası değerlerine doğrudan olasılıklar vermelidir. Bundan önceki altbölümdeki örnekte üretim yöneticisi “bu üretim süreci ile üretilen parçaların bozuk oranının 0.01 olması olasılığı 0.60'dır” diyebilmelidir.

Kuşkusuz, öznel önsel olasılıkların saptanmasında bir belirsizlik vardır. Örneğin yazın yağmurun yağma olasılığının 0.10 ile 0.30 arasında olmasından emin olabilirsiniz, ancak olasılığımızı temsil edecek tek bir sayı söylemek sizin için güç olabilir. Belirsizlik olan durumlarda, yukarıda anlatılanlar yararlı olabilir.

Şunu önemle belirtmek gerekir ki önsel olasılıkların belirlenmesinde kullanılan teknik ya da teknikler ne olursa olsun olasılıklar eksi olmamalıdır ve toplamı 1 olmalıdır. Eğer bunlar sağlanmazsa olasılıklar “tutarsızdır” denir.

Belirli, akılcı ve tutarlı değerlendirme belitlerine uyan bir değerlendirmeci (örneğin eğer A B’den daha çok olabilir ve B C’den daha çok olabilir diye varsayılıyorsa, A C’den daha çok olabilir varsayılmalıdır_bu bir geçişlilik belitidir), karar verme açısından her zaman tutarlı olacaktır. Böyle bir değerlendirmecinin olasılık belirlemelerinde tutarsızlık yoktur.

Bazı deneyler bireylerin olasılıkları her zaman akılcı bir biçimde belirlemediğini göstermiştir. Örneğin, çoğunlukla toplamı 1 olmayan olasılıklar saptanır (Belki dikkatsizlik, belirsizlik ya da değerlendirme yöntemlerinin yanlış anlaşılması nedeniyle). Her durumda bu büyük bir sorun oluşturmaz, çünkü eğer değerlendirmeci tutarsızlığın farkındaysa bu gidebilir. Eğer birisi, yaptığınız bir aritmetik yanlışı gösterirse kuşkusuz bu yanlışı düzeltebilirsiniz. Benzer biçimde eğer birisi önsel olasılıklarımızın toplamının 1.20 olduğunu söylerse, bu olasılıkları toplamı 1 olacak biçimde değiştirirsiniz. Buna göre, kimi zaman aynı olasılıkları daha değişik bir yolla saptamak yararlı olabilir. Birçok durumda, önsel olasılıkların saptanması için bir uzman tutulabilir.

Özet olarak, temel olasılık kavramını anlayan herkes kesikli bir olasılıksal değişken için bir önsel dağılım belirleyebilmelidir. Sürekli r.d.’lerle ilgilendiğimizde önsel dağılım belirlenmesi oldukça güç olabilir. Akılda tutacağınız ana fikir şu olmalıdır: Önsel dağılım örnekleme gözlemlmeden önce istatistikçiye elde edilebilir tüm bilgiyi yansıtabilmelidir.

1.6. OLABİLİRLİKLERİN BELİRLENMESİ

Önsel olasılıkların belirlenmesi Bayesci çıkarsama ve kararda önemli bir sorundur. Bayesci modele bir başka girdinin belirlenmesi de oldukça önemlidir. Birçok durumda veri yaratan süreci (ki yeni örneklem bilgisi yaratır) iyi bilinen bir istatistiksel modelle temsil etmek olanaklıdır.

Örneğin Altbölüm 1.2’de Bernoulli süreci daha önceden belirtildiği gibi durağanlık ve bağımsızlık varsayımları gerektirir. Kuşkusuz, gerçek yaşamda veri üreten süreçler, herhangi bir istatistiksel modelin varsayımlarına tümüyle uymazlar, uymayabilirler. Dolayısıyla, bir istatistiksel modelin, (herhangi bir matematiksel modelde olduğu gibi) uygulamada gerçekleşmesini umamayacağımız bir idealleştirme olduğunu bilmeliyiz.

Bununla birlikte, pek çok durumda gerçeğe yakın bir yaklaşıklık olabilir. Altbölüm 1.2’de Bernoulli modelinin kullanımı, olabirliliklerin belirlenmesini yalınlaştırdı, çünkü olabirlilikler binom dağılımı ile verilebildi.

ÖRNEK : Bernoulli sürecinin dışında bir örnek olarak otomobil satış yerinin sahibi olan bir kişinin sorununu ele alalım. Firma sahibi, satıcılarının iyi olup olmadığı ile ilgilenmektedir. Özel olarak bunların araba satışındaki başarıları ya da başarısızlıkları ile ilgilenmektedir. Geçmişteki deneyimlerden satıcıları kabaca üç bölüme ayırabilmektedir: “Çok iyi”, “iyi”, “zayıf”.

Çok iyi satıcı “gün aşırı bir araba” hızıyla satış yapmaktadır. Bu, satıcının kesinlikle gün aşırı bir araba satacağı anlamına gelmemektedir. Kimi dönemlerde hiç araba satamazken kimi günler birçok araba satabilir. Ancak ortalama olarak iki günde bir araba satmaktadır. “iyi” satıcı “dört günde bir araba” hızıyla, “zayıf” bir satıcı ise “8 günde bir araba” hızıyla satış yapmaktadır.

Firma sahibi araba satma sürecinin λ /gün yoğunluğu ile Poisson süreci olduğunu varsaymak istemektedir. λ nın üç olası değeri vardır: $\frac{1}{2}$ (Çok iyi satıcı), $\frac{1}{4}$ (İyi satıcı), $\frac{1}{8}$ (Zayıf satıcı).

Firma sahibi yeni bir satıcıyı işe almıştır. Geçmişteki deneyimlerine dayanarak ve kişisel bir görüşme ile firma sahibine göre yeni işçinin “çok iyi” bir satıcı olması şansı 4 e karşı 1 aleyhinedir, ancak “iyi” bir satıcı olması şansı eşittir.

Firma sahibi bu tür olasılıkların bir satıcının iyiliğine ilişkin bahisler için uygun olduğunu (adil olduğunu) düşünmektedir. Buna göre, satıcının “çok iyi” olması olasılığı $1/(1+4) = 0.2$ ve “iyi” olması olasılığı ise $1/(1+1)=0.5$ tir. Buradan geriye yalnızca “kötü” satıcı olma seçeneği kaldığından bu seçeneğin olasılığı 0.3’tür. Bu durumda firma sahibinin λ için önsel dağılımı, aşağıdaki olasılıklarla temsil edilebilir:

Yeni satıcının 24 çalışma günlük bir dönem için denendiğini varsayalım. Bu 24 günde satıcı 10 araba satmıştır. λ ’nın dağılımını yenilemek için Bayes teoremini uygulamada, firma sahibi olabilirlikleri saptamak için Poisson dağılımını kullanabilir, çünkü sürecin Poisson olduğunu varsaymıştır. Buna göre Poisson çizelgelerinden olabilirlikler elde edilebilir ya da aşağıdaki gibi hesaplanabilir:

olarak bulunur.

Bayes teoremi,

$$P(\lambda_i / y) = \frac{P(y / \lambda_i)P(\lambda_i)}{\sum_j P(y / \lambda_j)P(\lambda_j)}$$

biçiminde yazılabilir. Burada y örneklem sonucudur: 24 günde 10 satış olmasıdır. Sonsal olasılıklar Çizelge 1.6.1.'de saptanmıştır.

Çizelge 1.6.1. Otomobil satıcısı örneğinde Bayes teoremi.

λ	Önsel olasılıklar	Olabilirlikler	(Önsel olasılıklar) x (Olabilirlikler)	Sonsal olasılık


“Çok iyi” , “iyi” ve “kötü” satıcı için önsel olasılıklar sırasıyla 0.2, 0.5 ve 0.3 tür. Örneklem bilgisini gördükten sonra yenilenmiş (ya da sonsal olasılıklar) 0.501, 0.493 ve 0.006 dır. Bu, yeni satıcının 24 günlük dönemde yeterli araba satarak kendisinin kötü satıcı olmadığına firma sahibini inandırdığına ve firma sahibinin kestirimde kendisinin “çok iyi” satıcı olduğuna ilişkin bahis (şansını) olasılıklarını çok yükselttiğine yorumlanabilir.

λ nın önsel ve sonsal beklenen değerleri 0.261 ve 0.375 dir.


Örneklem bilgisini görmeden önce firma sahibi ortalama olarak satıcının günde 0.26 araba (3.84 günde 1 araba) satacağını kestirecekti.

Satıcı 24 günde 10 araba sattıktan sonra, firma sahibi satıcının ortalama olarak günde 0.37 araba satacağını düşünmektedir (ya da 2.70 günde 1 araba).

Önsel ve sonsal dağılımları Şekil 1.6.1. ve Şekil 1.6.2. de verilmiştir.



Şekil 1.6.1. Otomobil satıcısı örneğinde λ 'nın önsel dağılımı



Şekil 1.6.2. Otomobil satıcısı örneğinde λ 'nın sonsal dağılımı

ÖRNEK : Kesikli önsel dağılımların sürekli bir veri yaratan süreçle kullanımını görmek için bir gıda maddeleri satan mağazalar sahibinin mağazalarından birisindeki haftalık satışlarının dağılımı ile ilgilenildiğini varsayalım.

Özel olarak X r.d. nin (haftalık satışlar, \$ olarak) bilinmeyen ortalama μ ve bilinen varyans $\sigma^2 = 90\ 000$ ile normal dağıldığını varsaymak istemektedir.

Burada yapılan varsayımın öznel bir varsayım olduğunu belirtmek gerekir. Belki de bu normallik varsayımı, araştırdığı öteki mağazalarda X in yaklaşık normal dağıldığını gördüğünden ortaya çıkmaktadır.

Ayrıca sözkonusu mağazaya benzer öteki kimi mağazalarda ortalama haftalık satış mağazadan mağazaya değişmiş, ancak varyans 90 000 dolaylarında oldukça değişmez kalmıştır. Dolayısıyla mağaza sahibi sorunu yalınlaştıran ***bilinen σ^2 varsayımını*** yapmak istemektedir.

Son olarak bağımsız normal bir veri üreten model varsayımında gizli olarak sorun olacak eğilim (trend) ya da mevsimsel etki olmadığı varsayımını yapmaktadır. Yani sözkonusu mağaza türünde, satışlar zamanla büyük ölçüde değişmemekte ve hava, tatil, v.b. nedenlerden etkilenmemektedir. Bunlar bir istatistiksel model seçiminde gözönüne alınması gereken olağan varsayımlardır.

Mağaza sahibinin μ nün beş potansiyel değerini gözönüne almak istediğini varsayalım: 1100, 1150, 1200, 1250 ve 1300. Benzer mağazalardaki deneyimlere dayanarak aşağıdaki önsel olasılıkları belirlemiştir:

$$P(\mu = 1100) = 0.15 ,$$

$$P(\mu = 1150) = 0.20 ,$$

$$P(\mu = 1200) = 0.30 ,$$

$$P(\mu = 1250) = 0.20 ,$$

$$P(\mu = 1300) = 0.15 .$$

Mağaza sahibi satışlarla ilgili daha çok bilgi etmenin iyi olacağına karar verir ve mağaza geçmişteki satışlarından (değişik haftalardaki satışların birbirinden bağımsız olduğunu varsayarak) bir örneklem alır.

60 haftalık bir örneklemden ortalama haftalık satışı (örneklem ortalaması, $\bar{x}$) M=1240 olarak bulunur.

Bu örneklemi görmeden önce, μ verildiğine (bilindiğine) göre M nin koşullu dağılımı ortalama μ ve varyans $\sigma^2 / n = 90000 / 60 = 1500$ ile bir normal dağılımdı. Dolayısı ile olabilirlik fonksiyonu,

$$f(x/\mu, \sigma/\sqrt{n}) = \frac{1}{(\sigma/\sqrt{n})\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{\bar{x}-\mu}{\sigma/\sqrt{n}}\right)^2}$$

biçimindedir. Ancak eğer $z = \frac{(\bar{x}-\mu)}{(\sigma/\sqrt{n})} = \frac{(1240-\mu)}{38.73}$ dersek olabilirlik fonksiyonu,

$$f(1240/\mu, \sigma/\sqrt{n} = 38.73) = \frac{1}{38.73} \left(\frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}z^2} \right)$$

biçiminde yazılabilir. Bu örnekte M nin dağılımının standart sapması $\sigma/\sqrt{n} = 38.73$ tür.

Standart normal dağılımın olasılık yoğunluk fonksiyonu değerlerini kullanarak olasılıklar aşağıdaki gibi hesaplanabilir:

bulunur.


Bayes teoreminin, önsel dağılımının kesikli olması durumunda uygulanması çizelge biçiminde verilebilir.

Çizelge 1.6.2. Satışlar için Bayes teoreminin uygulanması.


μ	Önsel olasılıklar	Olabilirlikler	(Önsel olasılıklar) x (Olabilirlikler)	Sonsal olasılık

Çizelgeye dikkat edilirse herbir olabilirliğin paydası Bayes teoreminin uygulanması sırasında gider. Genel olarak tüm olabilirliklerin aynı değişmezle çarpımı ya da bölünmesi sonsal olasılıkları etkilemez, çünkü Bayes teoremi için olabilirliklerin “görelî (relatif)” değerleri gereklidir.

μ nün önsel ve sonsal dağılımlarının grafiksel gösterimleri Şekil 1.6.3 ve Şekil 1.6.4 ‘te verilmiştir.



Şekil 1.6.3. Satış örneğindeki μ nün önsel dağılımı



Şekil 1.6.4. Satış örneğindeki μ nün sonsal dağılımı

Bernoulli, Poisson ve normal modeller gibi istatistiksel modeller çıkarsama ve karar problemlerinde önemli rol oynarlar. Bunlar olabilirliklerin saptanmasını büyük ölçüde yalınlaştırırlar.

Birçok kişi belirli bir modelin varsayımlarını kabul etmek istediği için o modelden elde edilen olabilirlikleri de kabul etmelidirler.

Bununla birlikte bir modelin varsayımlarını kabul etmek istemek ve o modeli gerçek durumun doyurucu bir temsilcisi olarak gözönüne almak öznel bir seçimdir. Kişisel yargılar ister bir modeli seçmek için ister bir model kullanmaksızın, doğrudan olasılıkları saptamak için kullanılsın, bunda yine de öznellik ögesi vardır. Eğer bir istatistiksel model gerçekçi görünüyorsa olabilirliklerin saptanmasını yalınlaştırabilir, ancak bu modeli seçmedeki kararın öznel olduğu gözönünde bulundurulmalıdır.

Bazı durumlarda, veri üreten süreci iyi bilinen bir istatistiksel modelle temsil etmek olanaksız olabilir. Bu durumda önsel olasılıkların belirlendiği gibi olabilirlikler de doğrudan belirlenmelidir.

OLABİLİRLİKLERİN DOĞRUDAN BELİRLENMESİ

ÖRNEK : Olabilirliklerin belirlenmesine yalın bir örnek olarak, bir firmanın ürettikleri ürünlerin satışlarını oldukça etkileyecek yeni bir ürünü üretebilecek başka bir firma ile ilgilendiğini varsayalım. Firmanın müdürüne göre, karşı kuruluşun gerçekten yeni ürün üretmesi şansı 5 te 1 dir. Buna göre önsel olasılıklar,

$$P(\text{Yeni ürün}) =$$

$$P(\text{Yeni ürün yok}) =$$

biçimindedir.

Bu olasılıkları belirledikten sonra karşı firmanın **yeni bir fabrika kurduğu bilgisini alır**. Olasılıklarını Bayes teoremini kullanarak gözden geçirmek için bu yeni bilgiye ilişkin olabilirlikleri saptaması gerekmektedir.

Olabilirliklerden birisi “**yeni ürün tasarladığı bilindiğine göre karşı firmanın yeni bir fabrika kurması olasılığı**”, öteki olabilirlik ise “**yeni ürün için bir tasarı olmadığı bilindiğine göre yeni fabrikanın kurulması**” olasılığıdır.

Karşı firmanın durumunun dikkatle incelenmesi sonucu, firma müdürü yeni ürün üretecekse şansın (bahis olasılığının) 3 e 2 yeni bir fabrika kurulması lehine olduğuna karar verir. Öte yandan, eğer yeni bir ürün üretilmeyecekse bahisler 1 e 4 yeni bir fabrika kurulması yönündedir. Buna göre firma müdürünün olabilirlikleri,

$$P(\text{Yeni fabrika}/\text{Yeni ürün}) =$$

ve

$$P(\text{Yeni fabrika}/\text{Yeni ürün yok}) =$$

olur.

Alt bölüm 1.1. in yazılımını kullanarak eğer yeni bir ürün üretilcekse $\theta = 1$, üretilmeyecekse $\theta = 0$ olsun. Örneklem bilgisi y yeni fabrikanın kurulduğu biçimindedir. Şimdi Bayes teoremi Çizelge 1.6.3.’teki gibi uygulanabilir.

Çizelge 1.6.3. Yeni ürün örneği için Bayes teoremi.

θ	Önsel olasılıklar	Olabilirlikler	(Önsel olasılıklar) x (Olabilirlikler)	Sonsal olasılık

Yeni bir fabrika kurulduğuna ilişkin yeni bilgi $\theta = 1$ olması olasılığını (yani karşı firma, yeni bir ürün tasarlamaktadır) 0.2 den 0.43 e artırmaktadır.

Dikkat edilirse olabilirlikler ilgili koşullu olasılıkların herhangi bir katı (çarpımı) olarak alınabildiğine göre yalnızca “**görelî=relatif**” **olabilirlikleri** vermek yeterli olmaktadır. Bir başka deyişle, $P(\text{Yeni fabrika}/\text{Yeni ürün}) = 0.6$ ve $P(\text{Yeni fabrika}/\text{Yeni ürün yok}) = 0.2$ biçiminde belirlemek yerine “yeni ürün olduğu verildiğine göre yeni fabrika kurulması, yeni ürün olmadığı verildiğine göre yeni fabrika kurulmasının 3 katıdır” demek yeterlidir.

Genel olarak, ilgilenilen tüm koşullu olasılıkları belirlemek yerine görelî olabilirlikleri belirlemek daha kolaydır.

1.7. SÜREKLİ OLASILIKSAL DEĞİŞKENLER İÇİN BAYES TEOREMİ

İstatistiksel çıkarsama ve karara ilişkin birçok sorunda, ilgilenilen o.d.'in sürekli olduğunu varsaymak daha gerçekçi ve uygundur.

Daha önce vurguladığımız gibi ölçme yöntemleri öyledir ki gözlemlenen o.d.'ler hiçbir zaman gerçekten sürekli olamazlar. Bununla birlikte, birçok durumda ölçümler yeterli derecede kesin olabilir ve uygulama açısından bir o.d.'in sürekli olduğunu varsayabiliriz.

Gerçekten birçok durumda bir o.d.'nin sürekli olduğunu varsaymak oldukça gerçekçi görülebilir.

Örneğin Altbölüm 1.2'deki kalite denetimi örneğinde bozuk oranı p nin yalnızca dört değer 0.01, 0.05, 0.10, 0.25 değerlerini aldığını varsaymak yerine sürekli bir o.d. olduğunu varsaymak daha gerçekçidir.

Eğer ilgilenilen parametre θ sürekli ise θ 'nın önsel ve sonsal dağılımları yoğunluk fonksiyonları ile temsil edilebilir.

Ayrıca, θ 'ya ilişkin örneklem bilgisi, örneklem değer (istatistik) Y ile özetlenebiliyorsa sonsal yoğunluk yalnızca Y 'nin gözlemlenen değeri y verildiğine göre θ 'nın koşullu yoğunluğudur.

Önceki bilgilerimizden,

$$f(\theta/Y=y) = \frac{f(\theta,y)}{f(y)} \quad (1.7.1)$$

biçiminde yazılabilir. İkinci bir o.d. bilindiğinde bir o.d.'in koşullu yoğunluğu bu iki o.d.'in bileşik yoğunluğu bölü ikinci o.d.'in bileşen (marjinal) yoğunluğudur.

Bileşik yoğunluk $f(\theta,y)$ ve marjinal yoğunluk $f(y)$ bilinmiyor. Biz yalnızca önsel dağılım $f(\theta)$ ve olabilirlik fonksiyonu $f(y/\theta)$ 'yı biliyoruz.

$$f(\theta, y) = f(\theta)f(y/\theta) \quad (1.7.2)$$

$$f(y) = \int_{-\infty}^{\infty} f(\theta, y)d\theta = \int_{-\infty}^{\infty} f(\theta)f(y/\theta)d\theta \quad (1.7.3)$$

Bayes teoreminin olağan biçimi Eşitlik (1.7.1)'in pay ve paydasını Eşitlik (1.7.2) ve Eşitlik (1.7.3)'teki terimlerle belirterek elde edilir. Buna göre sürekli o.d.'ler için Bayes teoremi aşağıdaki gibi yazılabilir:

$$f(\theta/y) = \frac{f(\theta, y)}{f(y)} = \frac{f(\theta)f(y/\theta)}{\int f(\theta)f(y/\theta)d\theta} \quad (1.7.4)$$

$f(\theta)$: önsel dağılım

$f(y/\theta)$: olabilirlik fonksiyonu

$f(\theta/y)$: sonsal dağılım

Burada önsel ve sonsal dağılımların uygun yoğunluk fonksiyonları olması gerekiyorsa da, buradaki sürekli o.d.'leri için kullanılan terimler, kesikli o.d.'ler için olduğu gibi yorumlanabilir.

Yani, negatif olmamalıdır ve eğri altındaki toplam alan (yoğunluk fonksiyonunun tüm tanım kümesi üzerinden integrali alınarak elde edilir) 1'e eşit olmalıdır.

Eşitlik (1.7.4)'ün paydasındaki integral Eşitlik (1.2.1)'in paydasındaki toplamla aynı amaca hizmet eder, sonsal dağılımı uygun bir olasılık dağılımı yapar.

Kesikli durumda olduğu gibi, olabilirlik fonksiyonu y değişmez olarak (y 'nin gözlemlenen değerine eşit) θ 'nın bir fonksiyonudur.

Sürekli olasılıksal modeller için Bayes teoreminin, kesikli olasılıksal modeller için Bayes teoremi ile aynı olduğu görülebilir.

Kesikli durumda Bayes teoremi sözcüklerle,

$$\text{Sonsal olasılık} = \frac{(\text{Önsel olasılık}) * (\text{Olabilirlik})}{\sum (\text{Önsel olasılık}) * (\text{Olabilirlik})}$$


biçiminde verilebilir ve karşılık gelen sürekli o.d.'ler için ifade ise,

$$\text{Sonsal yoğunluk} = \frac{(\text{Önsel yoğunluk}) * (\text{Olabilirlik})}{\int (\text{Önsel yoğunluk}) * (\text{Olabilirlik})}$$

ÖRNEK : Eşitlik (1.7.4)'ü anlatmak için $\theta=p$ nin yeni bir ürünün pazar payını temsil ettiğini varsayalım. Bu yeni ürün, aynı ürünün öteki türlerinden oldukça farklıdır. Bu nedenle yeni ürünün pazar payı kesin değildir. Pazarlama yöneticisi yeni bir ürünün belki de tüm pazarı çekebileceğini düşünmektedir (yani $p=1$ 'e yakın olmalıdır). Öte yandan, bu yeni ürünün hiç tutulmayacağı ya da az başarılı olacağı da göz önüne alınmaktadır.

Yönetici p 'yi sürekli varsayar ve p 'nin dağılımı için üçgen biçimli bir yoğunluk belirler: (Şekil 1.7.1)

$$f(p) = \begin{cases} 2(1-p), & 0 \leq p \leq 1 \\ 0, & \text{ö.d.} \end{cases}$$



Şekil 1.7.1. Pazar payı örneğinde p 'nin önsel dağılımı

p'ye ilişkin deneysel bazı bilgiler elde etmek için ürünün 5 müşteriden oluşan bir örneklem alınır. Bunlardan 1 müşteri yeni marka ürünü, öteki 4 müşteri öteki markalardan ürünleri alırlar.

Pazarlama yöneticisi örneklemin rasgele olduğunu ve satın alma sürecinin bir Bernoulli süreci ile temsil edilebileceğini varsaymak istemektedir.

Buna göre olabilirlik fonksiyonu $R=1$ değişmez ve p değişen olmak üzere binom dağılımı ile temsil edilebilir.

Olabilirlik fonksiyonu aşağıdaki gibidir:

$$f(y/p) = P(R/n, p) = \binom{n}{R} p^R (1-p)^{n-R}$$


$$f(y/p) = P(R = 1/n = 5, p) = \binom{5}{1} p^1 (1-p)^4 = 5p(1-p)^4.$$

Bu olabilirlik fonksiyonu Şekil 1.7.2'de verilmiştir. Eşitlik (1.7.4)'ü uygulayarak,


$$f(p/y) =$$

elde edilir. Dolayısı ile sonsal dağılım aşağıdaki gibi elde edilmiştir:

Sonsal dağılım Şekil 1.7.3.'te verilmiştir. Şekil 1.7.1 ile Şekil 1.7.3'ün bir karşılaştırması yapılırsa, yeni bilginin pazarlama yöneticisinin önsel dağılımını nasıl değiştirdiği görülebilir.



Şekil 1.7.2. Pazar payı örneğinde olabilirlik fo



Şekil 1.7.3. Pazar payı örneğinde p'nin sonsal d